

PaperPass[免费版]AIGC检测报告

简明打印版

AIGC总体疑似度(高+中+轻): 49.53%

AIGC总体疑似度(高+中+轻): 32.83% (加权计算)

高度疑似AIGC占全文比: 1.82%
中度疑似AIGC占全文比: 40.85%
轻度疑似AIGC占全文比: 6.86%
不予检测文字占比: 27.97%

检测版本: 免费版(仅检测中文)

报告编号: G7Y26A0843565693F

论文题目: 毕业论文-已压缩

论文作者: 佚名

论文字数: 56139

段落个数: 335

句子个数: 1510

片段个数: 208

提交时间: 2026-5-16 18:13:42

查询真伪: <https://www.paperpass.com/check>

疑似度分布图:



正文中片段的不同颜色表示不同的疑似度范围

- 红色: AIGC生成疑似度在70%以上 (高度疑似)
- 橙色: AIGC生成疑似度在60%~70% (中度疑似)
- 紫色: AIGC生成疑似度在50%~60% (轻度疑似)
- 黑色: AIGC生成疑似度在50%以下
- 灰色: 过短片段、标题和英文等不予检测的文字

注: AIGC检测可有效识别文本是否部分或全部由AI模型生成, 检测结果与论文质量无关、仅表示论文中内容片段存在AI生成可能性的概率。

加权计算公式: (片段1疑似度 + 片段2疑似度 + ... + 片段n疑似度) / n
片段疑似度范围0.0~1.0, 合格片段按照0计算, 不计算不予检测文字

AI 70%

武汉科技大学本科毕业论文本体感知自适应奖励四足跨地形控制 Proprioception-Driven Adaptive Reward Scheduling for Cross-Terrain Quadruped Locomotion 学院：人工智能与自动化学院专业：机器人工程学生姓名：杜云帆学号：202204416388 指导教师：陈志环 2026 年 4 月摘要四足机器人正越来越多地出现在灾害救援、野外巡检等非结构化场景中，但想在复杂地形下兼顾效率与稳定性仍是一个难点。基于强化学习的运动控制器里，混合内模方法只用本体感知信号就能达到不错的鲁棒性。不过这类方法的奖励函数大多采用固定权重，地形风险变了，策略偏好却没法跟着调——结果平地上速度和能效上不去，崎岖路段又容易摔倒。

本文以 HIMLoco (Hybrid Internal Model for Locomotion) 为基础框架，设计了一套本体感知驱动的自适应奖励调度方案。该方案用姿态波动、关节力矩变化、足端接触稳定性和动作平滑度四个维度的信号构造地形难度指标，再经过带约束的权重映射函数，把速度跟踪、能耗抑制、姿态稳定和抗扰恢复这几项子奖励的权重做动态分配。调度过程中还加入了指数平滑和变化率限制，防止在线调整引发奖励信号高频震荡。

AI 65%

我们在 Isaac Gym 上搭建了跨地形训练与评测管线，把固定权重基线和自适应调度方法做了系统对比。结果显示，在中低风险地形上自适应调度能提高速度和单位能效，在高风险地形上能降低姿态波动和跌倒率，整体表现优于固定权重方案。结合 HIMLoco 已公布的实验结果来看，这套方法不需要额外加装外感知传感器，也不用改核心策略网络，有较好的即插即用性和跨平台迁移潜力。

关键词：四足机器人；强化学习；本体感知；自适应奖励调度；跨地形运动控制 | Abstract Quadruped robots are promising for disaster response, field inspection, and unstructured operations. However, agile locomotion over diverse terrains remains challenging due to the trade-off between efficiency and stability. Existing learning-based controllers, including Hybrid Internal Model approaches, achieve strong robustness with proprioceptive sensing only. Yet, most of them rely on fixed-weight reward functions, which cannot adapt policy priorities online as terrain risks change.

This thesis proposes a proprioception-driven adaptive reward scheduling method built upon the HIMLoco framework. We first construct a terrain difficulty indicator using body attitude fluctuation, joint torque variation, foot contact stability, and action smoothness. Then a constrained mapping dynamically reallocates reward weights among velocity tracking, energy regularization, posture stability, and disturbance recovery terms. To ensure training stability, exponential smoothing and rate-limit constraints are introduced to suppress high-frequency oscillation in online scheduling.

A cross-terrain training and evaluation pipeline is established on Isaac Gym with massively parallel simulation. Comparative experiments between the fixed-weight baseline and the proposed scheduler, together with ablation studies, show that adaptive scheduling improves velocity and unit-distance energy efficiency on low-to-medium risk terrains while reducing posture fluctuation and fall rate on high-risk terrains. In combination with public HIMLoco evidence, the method demonstrates strong practicality as a plug-in module without extra exteroceptive sensors or major architecture changes.

Keywords: quadruped robot; reinforcement learning; proprioception; adaptive reward scheduling; cross-terrain locomotion

目 录 1 绪论 1.1 研究背景与意义.....1.2 国内外研究现状.....3 1.3 研究目标与主要贡献.....6 1.4 研究问题定义与技术路线.....6 1.5 本文组织结构.....7 1.6 本章小结.....7 2 相关理论与技术基础 2.1 四足机器人坐标系与运动学.....8 2.2 典型步态与节律.....13 2.3 马尔可夫决策过程.....15 2.4 策略梯度与 PPO 推导.....17 2.5 Actor-Critic 网络架构.....20 2.6 HIMLoco 框架与内部模型.....22 2.7 四足机器人无模型强化学习环境.....23 2.8 策略模型与本体感知输入.....25 2.9 Sim2Real 迁移技术.....26 2.10 多目标奖励与固定权重的局限.....27 2.11 本章小结.....28 3 基于本体感知的自适应奖励调度方法 29 3.1 方法总

体框架.....	29	3.2 地形难度估计.....	30	3.3 奖励权重动态映射.....	31
4 训练与推理过程.....	32	3.5 速度-地形双课程融合方法.....	33	3.6 平坦地形下的运动控制任务.....	35
.....	35	3.7 复杂度与稳定性分析.....	37	3.8 参数设置与工程实现细节.....	38
.....	38	3.9 本章小结.....	38	4 基于课程学习的训练优化方法	39
基础.....	39	4.2 速度指令课程设计与验证.....	40	4.3 地形课程设计与验证.....	44
.....	44	4.4 速度-地形双课程融合方法.....	48	4.5 本章小结.....	50
III 5 结果与分析	51	5.1 总体性能对比.....	51	5.2 仿真迁移实验.....	51
.....	51	5.4 失败案例与可解释性.....	63	5.5 综合讨论.....	64
.....	57	5.6 本章小结.....	64	6 结论与展望	65
.....	64	6.1 研究工作总结.....	65	6.2 主要结论.....	65
.....	65	6.3 方法局限与适用边界.....	66	6.4 工程部署与 Sim2Real 展望.....	67
.....	67	6.5 后续研究方向.....	68	致谢	70
IV 插图 1-1 早期四足机器人探索: Walking Truck 与 SILO4.....	1	1-2 波士顿动力四足机器人发展概览.....	2	1-3 典型四足机器人跨地形运动序列, 展示了本体感知控制器在连续接触切换、姿态恢复与速度保持过程中的动态响应。.....	3
.....	1	1-4 ETH Zurich 四足机器人: StarlETH (a) 与 ANYmal (b).....	4	1-5 MIT Cheetah 系列: 第一代 (a)、第二代 (b)、第三代 (c).....	4
.....	4	1-6 四足机器人本体感知控制实验片段。该类连续姿态图能够直观反映策略在无外部视觉输入时依靠关节状态、IMU 与历史响应完成落足调整的过程。.....	5	1-7 宇树科技四足机器人产品线.....	5
.....	5	1-8 云深处绝影系列四足机器人: 绝影 X20 (a)、X30 (b)、Lite3 (c).....	5	2-1 四足机器人单腿坐标系与连杆结构示意.....	9
.....	9	2-2 横滚髋关节 q_1 求解示意 (YZ 平面投影).....	12	2-3 俯仰髋关节 q_2 与膝关节 q_3 求解示意 (XZ 平面投影).....	12
.....	12	2-4 四足机器人腿部机械结构示意。每条腿由髋关节、膝关节与足端连杆构成, 足端位置可由(2-7)所示正运动学关系计算。.....	13	2-5 单腿足端可达工作空间.....	13
.....	13	2-6 walk 步态时序 ($\beta = 0.75$).....	14	2-7 trot 步态时序 ($\beta = 0.50$).....	15
.....	14	2-8 强化学习智能体-环境交互框架.....	16	2-9 PPO 算法训练流程图。并行环境产生短轨迹, 轨迹缓冲池计算优势与目标回报, 随后通过截断策略目标、价值损失和熵正则共同更新 Actor-Critic 网络。.....	19
.....	19	2-10 非对称 Actor-Critic 网络结构示意图。Actor 仅使用部署可获得的本体信息与命令, Critic 在训练阶段额外接收特权状态以降低价值估计误差。.....	21	2-11 仿真环境中的四足机器人运动序列。图像展示了策略在不同接触相位下的姿态变化, 可作为 Actor 输出动作经低层 PD 控制后驱动机体运动的直观示例。.....	22
.....	22	2-12 内部嵌入在不同速度与负载条件下的二维可视化示例。不同颜色对应不同工况, 聚类分布可用于判断本体历史特征是否携带足够的环境判别信息。.....	23	2-13 仿真地形中的四足机器人连续运动片段。该类批量场景可用于观察策略在不同接触状态与地形风险下的动作稳定性。.....	25
.....	25	2-14 复杂接触条件下的四足机器人运动片段。连续画面体现了策略在支撑相切换、地形高度变化与姿态修正过程中的响应, 可用于辅助讨论 Sim2Real 场景中的接触不确定性。.....	27	V3-1 本体感知自适应奖励调度流程图。调度器位于奖励计算端, 通过本体信号估计地形难度, 并将多目标子奖励组合为供 PPO 使用的总奖励。.....	29
.....	29	3-2 训练过程中关键状态量与奖励相关量的曲线示例。多条时序曲线可用于观察策略收敛、控制波动与难度响应之间的关系。.....	32	3-3 融合 PPO、内部模型与自适应奖励调度的训练流程图。奖励调度器插入环境交互与轨迹入池之间, 不改变 Actor-Critic 主网络结构。.....	33
.....	33	3-4 速度-地形双课程推进示意图。实线表示满足阈值后的升级方向, 虚线表示跌倒率过高时的安全回退方向。.....	34	3-5 不同训练配置下的性能曲线示例。曲线随迭代上升并逐渐收敛, 可用于辅助说明课程训练对策略性能提升过程的影响。.....	35
.....	35	4-1 课程学习基本框架。难度测量器对任务进行分级评估, 训练调度器根据当前难度决定样本的采样概率与分布范围。.....	40	4-2 速度独立分布更新过程。线速度与角速度分别独立扩展, 训练后期难以有效覆盖高速高转速耦合指令区域。.....	41
.....	40	4-3 速度联合分布更新过程。线速度与角速度以联合概率密度方式同步扩展, 确保高速高转速耦合指令区域被充分覆盖。.....	42		

4-4 速度课程训练过程中的采样区域扩展（左）与奖励函数变化（右）。采样区域随训练逐步扩大，奖励在极限区域出现合理波动。42

4-5 最大纵向速度测试。经过速度课程训练后，机器人最大稳定跟踪线速度达到 6.2 m/s，展现出突出的高速运动潜力。43

4-6 最大横摆角速度测试。课程训练后机器人最高可跟踪 9 rad/s 转向指令，高转速下存在约 25% 的切换速度损失。43

4-7 线速度-角速度覆盖区域热力图。每个网格单元表示在该速度分辨率区间内角速度跟踪的成功程度，暖色区域表示高速高转向复合指令的稳定覆盖。44

4-8 训练地形分类。从左至右、从上至下依次为：光滑坡面、凹凸坡面、上楼梯、下楼梯、随机台阶与平地。44

4-9 通过特权观测空间感知地形。教师网络在仿真中获取地形高度真值，学生网络通过域适应从历史本体观测中学习隐式地形表征。45

4-10 特权空间感知足端临近点高度信息。每条腿足端周围以 $m \times n$ 点阵感知临近区域的高度变化，为策略提供落足安全性的隐式判断依据。46

4-11 地形难度等级训练收敛曲线。在 4000 次迭代后各类地形难度收敛至 5 级附近，模型达到稳定训练状态。47

4-12 四足机器人跨越地形能力验证。课程训练后机器人可爬上 12 cm 台阶、攀登 45°坡道、跨越 18 cm 障碍物。48

4-13 速度-地形课程同时训练效果。速度课程过快更新抑制了地形学习进程，二者之间相互制约导致各自效果均不及单独训练。48

VI4-14 速度-地形双课程融合训练结果。左图为加入速度截断后的采样区域扩展（在 11000 回合后覆盖指令范围的 50%），右图为地形难度等级收敛（大部分地形收敛至 6 级，高于单一课程的 5 级）。49

5-1 PyBullet 迁移仿真环境。左侧为平坦地形测试场景，右侧为随机粗糙地形测试场景，机器人需在本体感知条件下完成速度跟踪与姿态稳定。52

5-2 不同速度指令下的迁移仿真运动截图。策略在 0.5~3.5 m/s 范围内均可保持稳定运动，足端触地节律清晰、躯干姿态平稳。52

5-3 最大纵向速度试验。策略在 3.5 m/s 极限速度指令下仍保持稳定，姿态波动随速度增大呈超线性增长。53

5-4 最大横摆角速度试验。策略可稳定跟踪 3.0 rad/s 转向指令，极限转弯半径下仍保持躯干水平度。53

5-5 低附着系数路面工况试验 ($\mu = 0.2$)。策略通过自适应调节步幅与支撑相占比保持运动稳定性，速度跟踪误差较正常路面增大约 2 倍。54

5-6 5 kg 负载工况试验。附加 5 kg 负载后运动性能几乎无退化，速度跟踪误差与能耗增加均 <5%。54

5-7 10 kg 负载工况试验。附加 10 kg 负载后关节力矩峰值上升约 30%，但仍能维持稳定运动，未发生跌倒。54

5-8 崎岖越野地形下的连续运动截图。策略通过自适应落足调整应对高度变化 0~8 cm 的随机碎石凸起，躯干保持基本水平。55

5-9 崎岖越野地形工况试验数据。速度跟踪误差在崎岖段显著上升但仍保持有界，姿态波动方差较平坦地形增大 2~3 倍。55

5-10 坑洼越野地形下的连续运动截图。策略在随机深度 0~6 cm 凹陷中自动探索可行落足区域。55

5-11 坑洼越野地形工况试验数据。触地信号在坑洼区呈不规则切换模式，能量消耗较平坦地形增加约 40%。55

5-12 上楼梯-下坡复合地形关键运动帧。台阶高度 0.10~0.18 m，下坡坡度约 20°。策略在台阶段与坡道段之间自动完成步态参数切换。56

5-13 上楼梯-下坡复合地形试验数据。台阶段抬腿高度显著增大，坡道段躯干俯仰角主动调整以防止倾覆。56

5-14 上坡-下楼梯复合地形关键运动帧。上坡坡度约 18°，下楼梯台阶高度 0.10~0.15 m。56

5-15 上坡-下楼梯复合地形试验数据。下楼梯段关节力矩波动明显增大，策略通过缩短步幅和降低下落速度保证稳定。57

5-16 本体感受四足机器人实验平台。硬件系统包含 Unitree Go1 机器人、NVIDIA Jetson 计算单元与机载 IMU/编码器传感链路，策略仅依赖本体感受信息运行。57

5-17 3.5 m/s 高速奔跑 1 s 内的连续关键帧。策略保持清晰的 trot 对角步态，足端触地与离地时刻分明，躯干姿态平稳。58

VII5-18 最大速度下的运动稳定性数据。前向速度实测值在 3.3~3.5 m/s 范围内波动，姿态偏差始终控制在安全阈值以内。58

5-19 最高横摆角速度下的极限相位切换关键帧。策略在 3.0 rad/s 转向指令下仍保持交替对角支撑，相位切换干净利落。59

5-20 最大加速度下的运动稳定性。速度跟踪曲线平稳上升，加速度均值约 1.5 m/s²，无明显超调或迟滞。59

5-21 低附着路面（光滑瓷砖， $\mu \approx 0.25 \sim 0.35$ ）实机运动场景。策略通过增大支撑相占比与降低步幅自适应地调整运动模式。60

5-22 低附着路面下的运动稳定性。速度跟踪稳定性略有下降

但未发生失控打滑，姿态维持良好。	60
5-23 3.5 kg 负载下的敏捷运动帧图。负载条件下策略仍保持稳定步态，无明显姿态倾斜或速度退化。	61
5-24 3.5 kg 负载下的运动稳定性。速度跟踪误差与空载相比无明显退化 (<3%)，关节力矩峰值增加约 15%。	61
5-25 复合地形实机验证。(左) 上楼梯 (0.10~0.15 m) -下坡 (约 18°)；(右) 上坡 (约 18°) -下楼梯 (0.10~0.15 m)。	62
5-26 复合地形实机运行稳定性数据。上楼梯段通过率 87%，下楼梯段通过率 82%，全程综合通过率 78%。	62
5-27 室外自然地形实机测试。四种典型室外场景分别验证策略在外力扰动、柔软地面、坡度组合与半结构化路面上的适应能力。	63
5-28 多工况下的通过成功率汇总。本体感知策略在绝大多数工况下均达到 80%以上通过率，综合平均成功率约 89.5%。	63
VIII 表 格 2-1 四足机器人结构参数	8
2-2 四足机器人动力学参数	8
2-3 常见四足步态的相位偏移与占空比配置.	14
2-4 深度强化学习算法特性对比	17
2- 5 PPO 算法伪代码 (简化版)	20
2-6 典型四足机器人强化学习奖励项	28
3-1 地形难度特征的构造方式与物理含义.	30
3-2 自适应奖励调度训练流程伪代码.	33
3-3 平坦地形运动控制任务的阶段化训练设置	36
3-4 自适应奖励调度方法的关键超参数与推荐范围	38
4-1 四足机器人弗劳德数对比	43
4-2 地形难度等级设置	45
4-3 不同地形的速度采样范围	49
5-1 全部测试场景平均指标 (均值±标准差, 5 种子)	51
6-1 本文工作的主要结论归纳.	66
IX 武汉科技大学本科毕业论文 1 绪论 1.1 研究背景与意义近年来，随着工业自动化、应急救援、智慧巡检与国防侦察等任务对移动机器人提出更高的环境适应性需求，足式机器人作为兼具高机动性与强地形通过性的代表平台，已成为机器人学研究的重要方向。四足机器人的早期探索可追溯至 1968 年通用电气研制的 Walking Truck——首台液压驱动四足步行装置，虽需人工操控，却奠定了足式机器人结构基础。此后数十年间，平台从液压高负载军用向电机驱动消费级演进，如图 1-1 所示。	

AI 65%

图 1-1 早期四足机器人探索： Walking Truck 与 SILO4 与轮式或履带式机器人相比，四足机器人通过离散接触点与地面交互，可在沙地、碎石、楼梯、断崖、台阶、坡面等非结构化地形中保持机动性，具有“走得到、上得去、过得去”的天然优势。波士顿动力公司于 2019 年发布的 Spot、瑞士苏黎世联邦理工学院推出的 ANYmal、宇树科技的 A1/Go1/Aliengo、麻省理工学院的 Mini Cheetah 系列等平台，已经在管廊巡检、矿区勘探、抢险救灾、施工辅助乃至太空探索预研等多个真实场景中获得广泛验证。在我国，“十四五”规划与国务院《“十四五”机器人产业发展规划》明确将足式机器人与智能控制算法列为重点突破方向，使得四足平台的国产化与算法自主创新具有战略意义。

波士顿动力公司的 BigDog、LS3、Spot 等平台展示了四足机器人从液压高负载到电 1 武汉科技大学本科毕业论文机消费级的技术演进，如图 1-2 所示。

图 1-2 波士顿动力四足机器人发展概览四足机器人控制方法走过了一条从解析建模到端到端学习的发展路径。早期以解析建模为核心，代表工作有基于线性倒立摆与捕获点的步态规划、基于零力矩点（Zero Moment Point, ZMP）的稳定性判据、基于全身动力学的模型预测控制（Model Predictive Control, MPC）和基于全身阻抗（Whole-Body Impedance）的力位混合控制。这类方法物理可解释性不错，稳定性边界也清楚，问题是动力学辨识工作量大，还需要高频在线优化，碰上接触不连续、地形不可观、参数明显漂移这些情况就容易出问题。后来出现了“模型+学习”的混合阶段，研究者试着用学习手段做残差补偿、搜索步态参数或者替代高层规划，比如把强化学习当作低层控制器的“调参器”来用。再后来就是端到端无模型强化学习阶段——直接用神经网络从原始观测映射到关节目标角，借助大规模并行仿真在几小时内完成相当于数年实地训练的经验量，并在真实平台上展现出超越传统控制的鲁棒性和泛化能力[1-5]。

端到端范式下，控制策略不再依赖显式动力学方程，而是把环境复杂度塞进策略网络和价值网络里。这么做好有几个好处：一个统一框架就能处理多种地形和扰动，不用为每种场景单独写控制器；仿真随机化能给策略低成本地带来鲁棒性，省去了在真机上做大量危险标定的麻烦；奖励函数还能让复杂步态自然涌现出来，策略拿

到不同的速度命令会自动切换 walk、trot、bound 这些节律。但端到端也有新问题——第一，奖励函数通常是把多个子目标加权求和，固定权重跟不上地形的变化；第二，只靠本体感知（IMU、关节编码器、关节力矩）的策略看不到前面的地形，得靠内部模型和历史信息猜隐状态；

第三，从仿真到真实（Sim-to-Real）迁移还有执行器迟滞、传感噪声、接触建模误差这些系统性差距。本文要解决的就是第一个问题——奖励权重如何适应地形变化。

2 武汉科技大学本科毕业论文图 1-3 典型四足机器人跨地形运动序列，展示了本体感知控制器在连续接触切换、姿态恢复与速度保持过程中的动态响应。

如图 1-3 所示，跨地形机动并不是要把某个单一指标做到极致，而是速度、能效、稳定性、抗扰能力好几个方面的综合权衡。平地上应该尽量发挥速度来提高巡检效率，碎石坡面上得主动收小步幅防止滑移，遇到台阶要抬高腿避免绊倒，受到外部冲击时得赶紧调整支撑相分布把姿态拉回来。这些不同行为背后对应的是不同的奖励权重偏好。但现有的学习控制器基本都用静态权重，相当于对所有场景用同一套偏好来折中，当然没法同时满足这么多需求。本文就是针对这个问题，在不改主干策略网络、不加新传感器的前提下，加一个轻量级的“奖励权重在线调度器”，让策略偏好能跟着地形风险动态变化。

1.2 国内外研究现状解析建模方法以全身动力学方程和接触约束为基础，通过在线优化算关节力矩，在 21 世纪初到 2018 年左右一直是四足机器人控制的主流。Boston Dynamics 的 BigDog、LS3 和 Spot 系列大量使用了模型预测控制的思想——把机器人简化成单刚体或带腿质量的串联多体结构，每个控制步求解一个二次规划，同时满足摆动腿轨迹、支撑腿力分配和摩擦锥约束。ETH Zurich 从 StarlETH 到 ANYmal 的演进代表了另一条技术路线：

AI 58%

StarlETH 在腿部集成了弹簧阻尼装置来模拟肌肉的弹性储能，ANYmal 用了模块化执行器并加上了激光雷达和立体视觉，能在工业巡检和救灾场景中自主导航，如图 1-4 所示。

ANYmal 早期基于全身控制（WBC）框架，把任务空间拆成运动控制层、力分配层和执行器接口层，结构化环境里走得很稳，小坡也能爬。这类方法的好处是稳定性边界可证明、行为可预测、调试可解释，代价是需要精细的动力学辨识，每换一个地形或负载往往得重新调参，大范围场景变化不好覆盖。

3 武汉科技大学本科毕业论文图 1-4 ETH Zurich 四足机器人：StarlETH (a) 与 ANYmal (b) 把无模型策略梯度方法用到足式机器人上大约是从 2017 年前后开始的。MIT 的 Cheetah 系列是算法驱动硬件迭代的典型：第一代用低惯量电机直驱做到了高速奔跑，第二代加了髋关节侧展实现侧向运动和跳跃，第三代不靠视觉、只靠触地检测就能自己爬楼梯，如图 1-5 所示。Hwangbo 等[1]在《Science Robotics》上首次报道了把神经网络策略训练到 ANYmal 上的结果——核心是用并行仿真训练策略再加域随机化做迁移，在恶劣地形上比传统控制鲁棒得多。Lee 等[5]把高度图和本体感知融合起来训策略，ANYmal 在野外山地能长距离稳定行走。Kumar 等[2]提出的 RMA（Rapid Motor Adaptation）把策略拆成“环境因子编码器+条件控制策略”，部署时用历史本体观测在线推断环境因子，不靠外感知就能在不同地形间迁移。Rudin 等[3]搞出了基于 Isaac Gym 的“分钟级训练”范式，GPU 并行仿真把训练时间从几十个小时压到了几分钟。Miki 等[4]则展示了视觉和本体融合的策略在实际山地和冰雪环境中的长时间运行能力。

最近三年的进展大致沿着三个方向在走。一个是“感知-控制深度耦合”，把高度图、深度图甚至语义图直接接进策略网络来提高前瞻能力[6; 7]。另一个是“低传感深度自适应”，HIMLoco[8]是这方面的代表——通过对历史观测做对比学习拿到隐式环境表征，只靠 IMU 和关节编码器就能稳定通过复杂地形。第三个方向是“运动技能涌现与组合”，用参考动作模仿、能耗约束或者动物运动数据集来驱动策略涌现多种步态[9; 10]。本文的工作建立在第二个方向上，想在“最小传感配置”下进一步释放跨地形性能。

AI 70%

图 1-5 MIT Cheetah 系列：第一代 (a)、第二代 (b)、第三代 (c) 4 武汉科技大学本科毕业论文图 1-6 四足机器人本体感知控制实验片段。该类连续姿态图能够直观反映策略在无外部视觉输入时依靠关节状态、IMU 与历史响应完成落足调整的过程。

国内四足机器人在硬件平台、低成本驱动和工程部署这几个方面走得很快。宇树科技的 Go1/Go2 和 Aliengo 系列、云深处的 Jueying X20、蔚蓝智能、追觅科技，加上不少高校的研发平台，都已经有了完整的本体研发和算法迭代能力，如图 1-7 所示。

图 1-7 宇树科技四足机器人产品线云深处的绝影系列也是国内四足机器人商业化的代表，如图 1-8 所示。绝影 X20 配了多线激光雷达和双目视觉，支持动态避障和 SLAM 建图，能跨 180 mm 障碍物、爬 30°斜坡；绝影 X30 集成了红外热成像和毫米波雷达，没光照或者浓烟环境也能自主导航；

绝影 Lite3 是轻量化的教育平台，开放 ROS 接口，续航 3 小时以上。

图 1-8 云深处绝影系列四足机器人：绝影 X20 (a)、X30 (b)、Lite3 (c) 算法方面，国内学者在课程学习、奖励整形、感知融合和多步态切换等方向做了不少工作，在 ICRA、IROS、RA-L 这些会议期刊上也有拿得出手的成果。国内学位论文里也有好几篇围绕四足机器人强化学习控制的系统研究，比如基于深度强化学习的分层控 5 武汉科技大学本科毕业论文制、基于强化迁移学习的步态自适应、基于本体感受的复杂地形通过等，这些构成了本课题在国内的直接学术背景。

总的来看，国内外研究在“能跑起来”这个阶段已经有不少成果了，现在焦点正从单点性能突破转向跨地形统一策略、可解释行为塑造、长期运行可靠性和多机协同这些方向。这些方向都绕不开“奖励函数怎么在不同场景下表达不同偏好”这个问题，本文的方法就是针对这个共性问题给了一个能工程落地的轻量级方案。

1.3 研究目标与主要贡献本文围绕“仅依赖本体感知信息、在跨地形场景下实现速度-稳定性协同优化”这个核心问题展开。具体来说，先在 HIMLoco 框架上搭一个固定权重基线，搞清楚它在不同风险地形上的性能边界和瓶颈在哪；然后构造一个只靠本体信号的地形难度估计指标，作为在线风险评估的统一表征；接下来提出受约束的奖励权重在线调度机制，在大规模并行仿真里验证它的训练稳定性；最后搭一套跨地形多指标评测框架，从总体和分场景两个维度分析方法的收益来源。

围绕上述目标，本文的主要贡献体现在四个方面。其一，提出了一种无需额外外感知硬件、也不修改主干策略网络的奖励调度方法，使其能够以“即插即用”的方式集成到现有控制管线中；其二，设计了“难度估计-权重映射-平滑约束-异常回退”一体化机制，从理论与工程两个层面控制在线调度引入的训练扰动；其三，构建了包含速度跟踪、能效、姿态稳定、跌倒率与恢复成功率在内的多维评测协议，使方法收益具备更强的可解释性与可复现实验性；其四，结合双课程（速度-地形）训练流程与平坦地形基础任务，验证了该方法不会以牺牲基础能力为代价换取跨地形稳定性。

1.4 研究问题定义与技术路线为避免问题描述泛化，本文将研究任务形式化为：在仅依赖本体感知信号、命令空间为线/角速度三维向量、地形集合包含平地、坡地、粗糙坡地、台阶与离散障碍五大类的条件下，学习一个统一控制策略，使其在跟踪误差、单位距离能耗、姿态波动方差、跌倒率与外扰恢复成功率上同时取得可部署平衡。这个问题的难点来自三个方面。首先，地形风险不是能直接测的物理量，得靠 IMU 角速度、关节力矩、足端接触序列这些本体信号间接估计。其次，奖励权重需要随风险在线更新，但更新太快会破坏策略梯度一致性，太慢又发挥不了自适应的作用。最后，调度机制必须和现有策略主干保持低耦合，不能增加额外传感器、专用计算单元或者需要大量调参。

基于上述判断，本文的技术路线按“先建立基线、再构建难度表征、再引入调度机制、最后完成系统评测”的顺序展开。首先构建固定权重 HIMLoco 基线并冻结评测协议，然后设计难度特征集合，把姿态扰动、力矩变化、接触一致性与动作平滑度统一映射到 [0, 1] 区间的难度分数；在此基础上建立约束型权重映射函数，将难度分数投影到多奖励项权重空间，并用指数平滑和变化率裁剪保证调度平稳；最后通过双课程并行训练与分场景统计开展对比和消融实验。整条路线强调可解释、可复现和可工程接入这三 6 武汉科技大学本科毕业论文项原则。

1.5 本文组织结构全文共分六章。第一章绪论介绍研究背景、问题边界、贡献概述与技术路线。第二章梳理四足机器人强化学习控制所需的理论基础，包括坐标系与运动学、典型步态、马尔可夫决策过程、PPO 推导、

Actor-Critic 网络、HIMLoco 框架、并行仿真环境、Sim2Real 迁移与多目标奖励问题。第三章给出本文核心方法,包括总体框架、地形难度估计、奖励权重动态映射、稳定性约束、双课程训练、平坦地形任务、复杂度分析与工程实现细节。第四章描述实验平台、对比组、评价指标、测试场景、统计方法与可复现协议。第五章从总体收益、分场景收益、消融分析、失败案例与综合讨论多个维度展开结果分析。

AI 68%

第六章总结全文,说明方法局限,并给出面向真实硬件部署与后续研究的展望。

1.6 本章小结本章首先说明了四足机器人在工业巡检与应急救援等场景中的战略意义,回顾了从解析建模到端到端强化学习的演进脉络,并指出当前主流学习控制器在“奖励权重静态”这一问题上的共性瓶颈。随后给出本文的研究目标与四点贡献,定义了形式化研究问题与五步技术路线,并简述全文组织结构。后续章节将沿着“理论-方法-实验-分析-总结”的顺序展开。

AI 70%

7 武汉科技大学本科毕业论文 2 相关理论与技术基础 2.1 四足机器人坐标系与运动学四足机器人作为多刚体串联机构,其运动控制依赖于对腿部几何关系的精确描述。

运动学建模包含正、逆两类问题:正运动学由关节角度推算足端空间位置,逆运动学则由期望足端位置反解关节目标角。二者共同构成步态规划、足端轨迹生成与底层关节控制的理论基础。本节以 Go1 为参考平台,依次建立单腿坐标系、推导正/逆运动学闭式解与雅可比矩阵,并给出足端可达工作空间。

Go1 的主要结构参数与动力学参数如表 2-1 和表 2-2 所示。

表 2-1 四足机器人结构参数
 躯干 数值(m) 连杆 数值(m) 长 0.54 labad 0.080 宽 0.29 lhip 0.213 高 0.13 lknee 0.213
 表 2-2 四足机器人动力学参数
 刚体名称 质量(kg) 质心位置(m) 转动惯量(Ixx, lyy, lzz)(kg·m²)
 机身 4.800 [0,0,0] [1.61e-2, 3.65e-2, 4.47e-2]
 髋关节 0.510 [-5.41e-3, -7.4e-4, 6e-6] [3.05e-4, 5.91e-4, 3.97e-4]
 大腿 0.899 [-3.47e-3, -1.90e-2, -3.27e-2] [5.39e-3, 5.14e-3, 1.02e-3]
 小腿 0.158 [6.29e-3, 1.30e-3, -1.22e-1] [3.61e-3, 3.63e-3, 3.51e-5]
 足端 0.060 [0, 0, 0] [9.6e-6, 9.6e-6, 9.6e-6]
 为描述单腿各关节与足端之间的几何关系,本文在机体坐标系{B}之外,再为单腿建立四个局部坐标系{0}、{1}、{2}和{3}。其中,{0}固连于横滚髋关节安装位,作为单腿运动学分析的基准坐标系;{1}、{2}、{3}分别附着于横滚髋关节、俯仰髋关节与俯仰膝关节之后的连杆。图 2-1 给出了单腿坐标系与连杆结构的几何关系。为简化矩阵推导,本文令 q₁=q₂=q₃=0 时,{0}、{1}、{2}的原点重合且坐标轴方向一致。这样处理后,前两级关节变换仅保留旋转矩阵,而不产生额外平移项,便于采用标准齐次变换矩阵进行连乘运算。

8 武汉科技大学本科毕业论文 图 2-1 四足机器人单腿坐标系与连杆结构示意图
 刚体位姿由齐次变换矩阵表示为 $T = R p$ 01×3 1, (2-1) 其中 $R \in SO(3)$ 为旋转矩阵, $p = [x, y, z]^T$ 为位移向量。单腿机构中,横滚髋关节绕局部 x 轴旋转,俯仰髋关节和俯仰膝关节绕局部 y 轴旋转,因此相邻坐标系之间的齐次变换可写为 $T_{10}(q_1) = R_x(q_1)$ 03×1 01×3 1, (2-2) $T_{21}(q_2) = R_y(q_2)$ [0,-d,0]^T 01×3 1, (2-3) $T_{32}(q_3) = R_y(q_3)$ [0,0,l1]^T 01×3 1, (2-4) 其中 d 为髋部横向偏置,l1 为大腿长度。若足端点 P 在坐标系{3}下的齐次坐标记为 ${}^3p = [h_0, 0, l_2, 1]^T$, (2-5) 则足端在基准坐标系{0}下的齐次坐标可由矩阵连乘得到:

${}^0p = T_{10}(q_1)T_{21}(q_2)T_{32}(q_3){}^3p$. (2-6) 式(2-6)给出了单腿正向运动学的标准矩阵表达,也是后续雅可比矩阵与逆向运动学推导的统一起点。

9 武汉科技大学本科毕业论文 将式(2-6)中的矩阵连乘展开,并提取足端三维位置分量,可得单腿足端在坐标系{0}下的闭式表达式:

$$\begin{bmatrix} p_x \\ p_y \\ p_z \end{bmatrix} = \begin{bmatrix} l_1 \sin q_2 + l_2 \sin(q_2 + q_3) - d \cos q_1 - \sin q_1 \cdot l_1 \cos q_2 + l_2 \cos(q_2 + q_3) \\ -d \sin q_1 + \cos q_1 \cdot l_1 \cos q_2 + l_2 \cos(q_2 + q_3) \\ 0 \end{bmatrix} \quad (2-7)$$

式(2-7)清晰地揭示了三关节对足端位置的耦合作用: q₂ 与 q₃ 决定前向伸展与抬腿高度, q₁ 决定足端相对机体的横向展开及支撑多边形宽度。由于上述关系完全由标准矩阵连乘推得,因此便于直接嵌入运动规划、轨迹跟踪以及强化学习环境中的动作解释模块。

AI 70%

从工程角度看,正运动学模型不仅用于计算足端目标位置,还决定了接触检测、摆动腿轨迹可达性和地面

约束映射等关键环节。例如，给定关节角与关节角速度，便可通过足端位置和足端速度判断当前步态是否偏离预期 trot 节律，从而为后续奖励设计提供几何层面的判据。

对式(2-7)关于关节角向量 $q = [q_1, q_2, q_3]^T$ 求偏导，可得足端速度关于关节速度的线性映射 $\dot{p} = J(q)\dot{q}$, $J(q) = \frac{\partial p}{\partial q}$ 。(2-8)为书写简洁，记 $s_i = \sin q_i$ 、 $c_i = \cos q_i$ 、 $s_{23} = \sin(q_2 + q_3)$ 、 $c_{23} = \cos(q_2 + q_3)$ ，则速度雅可比矩阵可写为 $J(q) = \begin{bmatrix} 0 & l_1 c_2 + l_2 c_{23} & l_2 c_{23} & d s_1 - c_1(l_1 c_2 + l_2 c_{23}) s_1(l_1 s_2 + l_2 s_{23}) l_2 s_1 s_{23} - d c_1 - s_1(l_1 c_2 + l_2 c_{23}) - c_1(l_1 s_2 + l_2 s_{23}) & -l_2 c_1 s_{23} \end{bmatrix}$ 。(2-9)当 $\det J(q) \neq 0$ 时，关节速度与足端速度之间的关系可逆，即 $\dot{q} = J^{-1}(q)\dot{p}$ 。(2-10)这一定义在摆动腿轨迹跟踪和接触恢复控制中具有重要意义：它允许控制器将工作空间中的期望足端速度映射到关节空间执行命令。

进一步依据虚功原理，关节力矩与足端接触力之间满足 $\tau^T \delta q - F^T \delta p = 0$ 。(2-11)结合 $\delta p = J(q)\delta q$ ，可得 $\tau = J^T(q)F$ 。(2-12)式(2-12)说明力雅可比矩阵其实就是速度雅可比矩阵的转置。有了这个关系，地面对足端的作用力就能快速映射成电机关节力矩，省去了在实时控制里反复解完整逆动力学方程的麻烦，这也是四足机器人在线控制里常用的一种高效建模方式。

逆向运动学的目标是：在已知足端期望位置 $p^* = [p_x, p_y, p_z]^T$ 的条件下，求解对应的关节角向量 $q^* = [q_1, q_2, q_3]^T$ 。对三自由度单腿而言，可将求解过程分解为“横滚关节解耦”和“二维平面几何求解”两个步骤。

首先，在 yz 平面内处理横滚关节的影响。定义侧向投影半径与有效摆动平面距离为 $\rho = q p^2_y + p^2_z$, $L = p p^2_z - d^2$ 。(2-13)则横滚关节角可以表示为 $q_1 = \arctan 2(-p_y, p_z) - \arctan 2(d, L)$ 。(2-14)式(2-14)的几何含义是：先由足端在 yz 平面的投影确定总体偏转角，再扣除髋部横向偏置带来的几何修正。该步骤实质上完成了空间问题到二维问题的降维。

在求得 q_1 后，可将足端投影到由大腿和小腿构成的等效矢状平面。此时足端到俯仰髋关节的有效距离满足 $r^2 = p^2_x + L^2$ 。(2-15)由余弦定理，膝关节角 q_3 满足 $c_3 = r^2 - l_1^2 - l_2^2 / 2 l_1 l_2$ 。(2-16) $q_3 = \arctan 2 \pm q_1 - c_2^3, c_3$ 。(2-17)式(2-17)给出膝关节的两组数学解。考虑到四足机器人通常只允许单一主要弯折方向，实际应用中需结合关节限位、机械装配和默认站姿选择唯一可行支路。

进一步定义 $\phi = \arctan 2(p_x, L)$, $\psi = \arctan 2(l_2 \sin q_3, l_1 + l_2 \cos q_3)$ ，(2-18)则俯仰髋关节角可写为 $q_2 = \phi - \psi$ 。(2-19)式(2-19)的形式反映了标准几何逆解的本质： ϕ 描述足端相对髋部的目标方向，而 ψ 则是由两段连杆夹角引入的修正项。由此，单腿逆向运动学的解析解可总结为 $q^* = \begin{bmatrix} q_1 & q_2 & q_3 \end{bmatrix}^T$ 。(2-20)需要指出的是，若 $r > l_1 + l_2$ 或 $r < |l_1 - l_2|$ ，则目标点超出单腿可达工作空间；若计算出的关节角超出驱动器限位，则需通过轨迹缩放、足端重规划或动作裁剪进行修正。因此，在强化学习控制中将动作输出限制在默认姿态附近，不仅有助于稳定训练，也保证了逆向解始终落在物理可实现的关节域内。

图 2-2 横滚髋关节 q_1 求解示意 (YZ 平面投影) 图 2-3 俯仰髋关节 q_2 与膝关节 q_3 求解示意 (XZ 平面投影) 四足机器人整体动力学满足拉格朗日方程：

$M(q)\ddot{q} + C(q, \dot{q})\dot{q} + g(q) = S^T \tau + 4 \sum_{i=1}^4 J_i^T(q) F_i$ 。(2-21)其中 M 为广义惯性矩阵， C 包含科氏力与离心力项， g 为重力项， S 为执行器选择矩阵， F_i 为第 i 条腿的足端反作用力。学习控制器虽然不显式求解(2-21)，但 PD 控制器将动作映射为关节力矩、再驱动(2-21)演化，因而方程(2-21)是仿真器内部的真实物理基础。

图 2-4 四足机器人腿部机械结构示意图。每条腿由髋关节、膝关节与足端连杆构成，足端位置可由(2-7)所示正运动学关系计算。

在关节限位约束下 ($q_1 \in [-20^\circ, 20^\circ]$ 、 $q_2 \in [-39^\circ, 80^\circ]$ 、 $q_3 \in [-161^\circ, -51^\circ]$)，单腿足端可达工作空间如图 2-5 所示。该区域决定了步长与抬腿高度的合理取值范围。

图 2-5 单腿足端可达工作空间 2.2 典型步态与节律四足动物运动学中，步态由四条腿的相位偏移与占空比共同决定。设步态周期为 T 、占空比为 $\beta \in (0, 1)$ 、第 i 条腿的相位偏移为 $\phi_i \in [0, 1)$ ，则该腿在时刻 t 的相位变量定义为 $\theta_i(t) = t/T + \phi_i \bmod 1$ 。(2-22)当 $\theta_i(t) < \beta$ 时该腿处于支撑相，否则处于摆动相。常见的相位配置如

表 2-3 所示，对应了不同速度区间下能效与稳定性的最优组合。

13 武汉科技大学本科毕业论文表 2-3 常见四足步态的相位偏移与占空比配置步态 $\phi_{LF}\phi_{RF}\phi_{LH}\phi_{RH}$ β 适用速度 walk 0.00 0.50 0.75 0.25 0.75 极低速 trot 0.00 0.50 0.50 0.00 0.50 中速 pace 0.00 0.50 0.00 0.50 0.50 中速侧倾偏好 bound 0.00 0.00 0.50 0.50 0.40 高速 gallop 0.00 0.10 0.50 0.60 0.30 极高速 walk 与 trot 两种典型步态的支撑/摆动相序如图 2-6 和图 2-7 所示。

图 2-6 walk 步态时序 ($\beta=0.75$) 14 武汉科技大学本科毕业论文图 2-7 trot 步态时序 ($\beta=0.50$) trot 是中速速度区间最常见的步态，左前-右后与右前-左后两组对角腿同时摆动同时支撑，重心投影几乎始终落在两条对角支撑腿之间，因而具备良好的静稳定性边界。

从动力学上看，trot 对应一种近似周期化的“弹簧-质量”节律：摆腿期髋部前摆储能，触地瞬间通过腿部柔顺吸收冲击，再在支撑后段释放推进力。学习控制器无需显式给定参考轨迹，只需通过周期性触地奖励、足端腾空高度奖励与动作平滑度奖励，即可让策略自然涌现 trot 行为。本文奖励调度方法对“足端接触一致性”特征的依赖，正是建立在 trot 步态周期性触地节奏被破坏即意味着风险升高这一物理直觉之上。

真实生物在不同速度下会自然切换步态以最小化能耗。学习控制器同样可以在奖励函数中加入“能耗项”使策略自动涌现“低速 walk、中速 trot、高速 bound”的切换行为。本文实验在中速区间集中训练 trot 步态，但所提方法不依赖具体步态约束，可推广到多步态场景：当难度估计指标识别到高速命令对应的高频接触切换时，调度器会同步上调稳定项权重，从而避免高速失稳。

2.3 马尔可夫决策过程强化学习中，智能体与环境的交互过程如图 2-8 所示。

15 武汉科技大学本科毕业论文图 2-8 强化学习智能体-环境交互框架强化学习的标准框架是马尔可夫决策过程 (Markov Decision Process, MDP)，形式化为五元组 $M=(S,A,P,r,\gamma)$ 。其中 S 为状态空间、 A 为动作空间、 $P(s'|s,a)$ 为状态转移概率、 $r:S\times A\rightarrow R$ 为奖励函数、 $\gamma\in[0,1]$ 为折扣因子。给定策略 $\pi(\cdot|s)$ ，状态价值函数与动作价值函数定义为 $V_{\pi}(s)=E\pi^{\infty}\sum_{t=0}^{\infty}\gamma r_t|s_0=s, Q_{\pi}(s,a)=E\pi^{\infty}\sum_{t=0}^{\infty}\gamma r_t|s_0=s,a_0=a$ ，(2-23) 满足 Bellman 期望方程 $V_{\pi}(s)=E_{a\sim\pi}[r(s,a)+\gamma E_{s'}V_{\pi}(s')]$ 。优势函数 $A_{\pi}(s,a)=Q_{\pi}(s,a)-V_{\pi}(s)$ 衡量在状态 s 选择动作 a 相对策略平均水平的偏好，是策略梯度方法的核心信号。

在本文研究的四足机器人控制任务中，MDP 的各要素可以直接对应到机器人控制管线。状态由基座姿态、角速度、命令、关节角与角速度以及上一时刻动作等本体可测量构成；动作则是 12 维关节目标角偏移，经动作缩放并与默认关节角叠加后送入 PD 控制器；状态转移由刚体动力学方程(2-21)与接触求解器隐式决定，仿真器以高频数值积分推进系统演化；奖励由速度跟踪、能耗、姿态稳定、动作平滑和足端接触等多个子项加权得到：折扣因子本文取 $\gamma=0.99$ ，对应约 100 步的有效视野。

需要注意的是，由于本体观测无法完整刻画地形、外扰与执行器状态，严格意义上的马尔可夫性并不成立。HIMLoco 通过引入历史观测序列与内部嵌入近似补全隐状态，使有效状态尽可能满足马尔可夫性，从而保证策略梯度估计的合理性。

更准确地，四足控制任务实际上是部分可观马尔可夫决策过程 (POMDP)：观测 ot 是由真实状态 st 经过观测函数 $\Omega(\cdot|st)$ 产生的部分信息。POMDP 通常引入“信念状态”或“历史压缩表示”作为有效状态：

$z_t=E_{\psi}(ot-H:t-1)$ ，(2-24) 其中 E_{ψ} 为可学习编码器， H 为历史窗口长度。HIMLoco 中 z_t 进一步分解为显式速度分量与隐式表征分量，分别通过监督回归与对比学习进行训练，是兼顾可解释性与表达能力的代表设计。

16 武汉科技大学本科毕业论文 2.4 策略梯度与 PPO 推导表 2-4 归纳了主流深度强化学习算法的类型与适用空间。四足机器人运动控制为连续动作空间任务，PPO 作为 Actor-Critic 架构的代表方法，在训练稳定性与实现复杂度之间取得了较好折中，本文即以此为底层优化算法。

表 2-4 深度强化学习算法特性对比算法类型 状态空间 动作空间 Deep Q-Network (DQN) Value-Based 连续/离散 离散 Policy Gradient (PG) Policy-Based 连续/离散 连续/离散 Soft Actor-Critic (SAC) Actor-Critic 连续/离散 连续 Deep Deterministic Policy Gradient (DDPG) Actor-Critic 连续/离散 连续 Proximal Policy

Optimization (PPO) Actor-Critic 连续/离散 连续/离散策略梯度方法直接以参数化策略 π_θ 优化期望回报 $J(\theta) = E\pi_\theta \quad P_t \gamma r_t$ 。Sutton 的策略梯度定理给出 $\nabla J(\theta) = E(s,a) \sim \pi_\theta \quad \nabla_\theta \log \pi_\theta(a|s) Q\pi_\theta(s,a)$ 。(2-25)为降低方差，常以优势函数 $A\pi(s,a)$ 替代 $Q\pi(s,a)$ ，在期望意义下二者等价：

AI 63%

$\nabla J(\theta) = E\pi_\theta \quad \nabla_\theta \log \pi_\theta(a|st) A\pi_\theta(st, at)$ 。(2-26)在 PPO 算法中，优势函数 $A\pi_\theta(st, at)$ 的估计质量直接决定了策略更新的方向是否可靠。若估计偏差过大，策略会偏离真实改进方向；若估计方差过大，训练曲线又会明显震荡。因此，工程实现中通常采用广义优势估计（Generalized Advantage Estimation, GAE）在偏差与方差之间取得折中。

最基本的价值修正量是一步 TD 误差：

$\delta_t = r_t + \gamma V\phi(st+1) - V\phi(st)$ 。(2-27)式(2-27)只利用一步转移信息更新价值估计，因此方差较小，但由于严重依赖当前价值函数的近似精度，往往存在较大的估计偏差。

AI 52%

与之相对，若从时刻 t 一直累积到轨迹末端，则可得到蒙特卡洛回报：

$GMC_t = T - t - 1 \times \gamma \sum_{l=0}^{\infty} \gamma^l r_{t+l}$ 。(2-28)蒙特卡洛方法不再依赖中间状态的价值估计，因此偏差较小；但它需要等到整条轨迹结束后再统一回传奖励，故而方差通常较大。

17 武汉科技大学本科毕业论文为了在两者之间建立过渡，可先定义 n 步回报：

$\hat{R}(n)_t = n - 1 \times \gamma \sum_{l=0}^{\infty} \gamma^l r_{t+l} + \gamma^n V\phi(st+n)$, $n \geq 1$ 。(2-29)式(2-29)表明：当 $n = 1$ 时，它退化为一步 TD 目标；当 n 逐渐增大并延伸到轨迹末端时，它又逐步逼近蒙特卡洛回报。进一步对不同步长的回报做指数加权，便得到 λ -return：

$\hat{R}_\lambda t = (1-\lambda) \sum_{n=1}^{\infty} \lambda^{n-1} \hat{R}(n)_t + \lambda \sum_{N=1}^{\infty} \lambda^{N-1} \hat{R}(N)_t$ ，(2-30)其中 $N = T - t$ 为从时刻 t 到回合终止的剩余步数。式(2-30)的第一项对应短视的一步或少步回报，最后一项则对应整条轨迹的长视回报，因此 $\lambda \in [0,1]$ 实际上提供了一条从 TD 方法到蒙特卡洛方法的连续插值路径。

在此基础上，GAE 将 λ -return 引入优势函数估计，得到 $\hat{A}GAE(\gamma, \lambda)_t = \hat{R}_\lambda t - V\phi(st) = T - t - 1 \times \gamma \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}$ 。(2-31)由式(2-31)可见，GAE 本质上是对未来若干步 TD 误差做衰减累加：当 $\lambda = 0$ 时，优势函数退化为一步 TD 误差，方差最小但偏差较大；当 $\lambda = 1$ 时，它接近蒙特卡洛形式，偏差减小但方差上升。本文取 $\lambda = 0.95$ ，并对 $\hat{A}_t$ 在每个小批量内执行均值-方差归一化，以稳定后续 PPO 更新。

AI 70%

直接最大化策略梯度目标虽然形式简洁，但对更新步长非常敏感。若参数更新幅度过大，新策略往往会迅速偏离旧策略的有效采样分布，进而导致性能崩塌。为了解决这一问题，TRPO (Trust Region Policy Optimization) 在策略优化时引入了信任域约束：

$\max_\theta E \pi_{\theta_{old}} \quad r_t(\theta) \hat{A}_t, s.t. E \quad KL(\pi_{\theta_{old}} // \pi_\theta) \leq \delta$ ，(2-32)其中 $r_t(\theta) = \pi_\theta(at|st) \pi_{\theta_{old}}(at|st)$ 。(2-33)为重要性采样比率。式(2-32)的含义是：在提升优势动作概率的同时，显式限制新旧策略之间的 KL 散度不超过阈值 δ 。这种方法可以有效抑制策略“跳得过远”，但其求解依赖二阶近似、共轭梯度与线搜索，工程实现较为复杂。

AI 50%

PPO (Proximal Policy Optimization) 保留了“限制策略变化幅度”的思想，但不再直接求解带约束优化问题，而是用截断函数构造一个更易实现的一阶目标：

$LCLIP(\theta) = E \min \quad r_t(\theta) \hat{A}_t, clip(r_t(\theta), 1-\epsilon, 1+\epsilon) \hat{A}_t$ 。(2-34)式(2-34)中的截断区间 $[1-\epsilon, 1+\epsilon]$ 为概率比率设置了一个近端更新范围。其物理含义 18 武汉科技大学本科毕业论文可以分两种情况理解：当 $\hat{A}_t > 0$ 时，说明当前动作优于平均水平，此时 PPO 允许适度增大该动作概率，但超过 $1+\epsilon$ 的部分将不再继续获得额外收益；当 $\hat{A}_t < 0$ 时，说明该动作劣于平均水平，此时 PPO 会降低其概率，但下降幅度也会被限制在 $1-\epsilon$ 附近。这样一来，PPO 在保持优化稳定性的同时，避免了 TRPO 复杂的二阶求解过程，因此成为当前强化学习控制中应用最广的策略优化方法之一。

AI 68%

在实际实现中，PPO 并不是只优化式(2-34)中的策略项，而是同时联合考虑策略改进、价值拟合和探索保持三个目标。首先，价值网络损失写为 $LV(\phi) = E \quad (V\phi(st) - \hat{R}_t)^2$ ，(2-35)其中 $\hat{R}_t = \hat{A}_t + V\phi(st)$ 。(2-36)为对应的回报目标。该项要求 Critic 网络尽可能准确地逼近状态价值，从而为优势函数估计提供更稳定的基线。

AI 66%

其次，为避免策略在训练早期过快塌缩为近似确定性分布，通常还会加入熵正则项：

$LH(\theta) = E_{H \sim \pi_{\theta}(\cdot|st)}$ (2-37) 熵越大，说明策略保留的随机探索越充分；熵越小，则说明策略趋于确定性输出。

AI 66%

综合以上三项，可得 PPO 的完整训练目标：

$L_{total}(\theta, \phi) = L_{CLIP}(\theta) - c_1 LV(\phi) + c_2 LH(\theta)$ (2-38) 式(2-38)中，第一项负责推动策略朝优势更高的方向更新，第二项负责提高价值函数近似精度，第三项用于维持必要的探索能力。本文取 $c_1 = 1.0$ 、 $c_2 = 0.01$ ，并在每轮采样后对大批量数据执行多轮反向传播更新（典型为 5 轮），以充分利用并行环境产生的轨迹样本。

AI 67%

整体训练流程可概括为“并行环境采样→计算 GAE 与回报→多轮小批量 PPO 更新→同步新旧策略→进入下一采集周期”。这一“同策略+短轨迹+多轮复用”的设计在并行仿真平台上具备良好的样本效率与稳定性。图 2-9 给出 PPO 中数据流、优势估计与参数更新之间的关系，算法 2-5 给出对应伪代码。

AI 67%

并行环境 $N \times T$ 采样轨迹缓冲池(st, at, rt, st+1)优势估计 $\hat{A}_t$ 、 $\hat{R}_t$ 截断目标 LCLIP 参数更新 θ 、 ϕ Actor-Critic π_{θ}, V_{ϕ} 速度命令 ct 价值回归图 2-9 PPO 算法训练流程图。并行环境产生短轨迹，轨迹缓冲池计算优势与目标回报，随后通过截断策略目标、价值损失和熵正则共同更新 Actor-Critic 网络。

AI 69%

19 武汉科技大学本科毕业论文表 2-5 PPO 算法伪代码（简化版）输入：初始策略 π_{θ_0} 、价值网络 V_{ϕ_0} 、并行环境数 N 、轨迹长度 T 1: for 迭代 $k = 0, 1, 2, \dots$ do 2: 在 N 个并行环境中以策略 π_{θ_k} 采样长度为 T 的轨迹 3: 计算每条轨迹的 GAE 优势 $\hat{A}_t$ 与目标回报 $\hat{R}_t$ 4: 对 $\hat{A}_t$ 做小批量内均值-方差归一化 5: for epoch $e = 1, \dots, E$ do 6: 对 mini-batch 通过(2-38)更新 θ, ϕ 7: end for 8: 同步 $\pi_{\theta_{old}} \leftarrow \pi_{\theta_k+1}$ 9: end for 2.5 Actor-Critic 网络架构本文采用经典的 Actor-Critic 双网络架构。Actor 网络 π_{θ} 负责输出动作分布，Critic 网络 V_{ϕ} 负责估计状态价值，两者既可以共享前端表征也可独立设计。HIMLoco 采用独立结构，使 Actor 与 Critic 在训练阶段输入不同信息。

AI 65%

Actor 由一个三层多层感知机（MLP）构成：输入维度为本体观测 ot 拼接历史嵌入 zt 与命令 ct ，隐层宽度依次为 512-256-128，激活函数为 ELU，输出层为高斯分布的均值 $\mu_{\theta}(ot, zt, ct)$ ，标准差由可学习的状态无关向量 σ_{θ} 参数化：

$\pi_{\theta}(at|ot, zt, ct) = N(\mu_{\theta}(ot, zt, ct), \text{diag}(\sigma_{\theta}^2))$ (2-39) 上述网络可用图 2-10 表示。图中实线表示部署阶段仍然保留的数据通路，虚线表示仅在训练阶段用于提升价值估计或构造奖励的辅助通路。

AI 70%

20 武汉科技大学本科毕业论文本体观测 ot 历史嵌入 zt 速度命令 ct Actor 网络 512-256-128 高斯策略 $\mu_{\theta}, \sigma_{\theta}$ 关节目标 $at \in R^{12}$ Critic 网络 $V_{\phi}(st)$ 特权状态 pt 优势估计图 2-10 非对称 Actor-Critic 网络结构示意。Actor 仅使用部署可获得的本体信息与命令，Critic 在训练阶段额外接收特权状态以降低价值估计误差。

AI 68%

仿真训练中 Critic 可访问“特权信息” pt ，包含基座线速度真值、地形高度图、足端接触力等部署阶段难以测量的量，从而提供更准确的价值估计。这种“训练用全信息、部署用本体信息”的非对称设计是当前足式机器人学习控制的事实标准，能够在不增加部署成本的前提下提高 Critic 拟合质量并加速 Actor 收敛。

AI 69%

21 武汉科技大学本科毕业论文图 2-11 仿真环境中的四足机器人运动序列。图像展示了策略在不同接触相位下的姿态变化，可作为 Actor 输出动作经低层 PD 控制后驱动机体运动的直观示例。

为保证训练初期稳定，本文对网络参数采用正交初始化，最后一层权重缩放系数为 0.01，使初始策略输出接近零均值，避免过激探索；可学习标准差初始化为 $\sigma_{\theta} = \exp(0)1 = 1$ ，对应单位方差高斯探索。优化器使用 Adam，学习率初始化为 1×10^{-3} ，并采用基于近期 KL 散度的自适应衰减：当一次 PPO 更新中 $KL(\pi_{\theta_{old}} // \pi_{\theta})$ 超过阈值 $1.5 \delta_{target}$ 时，立即将学习率减半；低于 $0.5 \delta_{target}$ 时则放大 1.5 倍。该自适应策略在不增加调参成本的同时显著提升了训练曲线的平稳性。

AI 70%

2.6 HIMLoco 框架与内部模型 HIMLoco 的核心思想是将“环境扰动”信息通过“机器人响应”隐式建模[8]。换言之，由于地形高度、摩擦系数、外部冲击等隐变量不可直接测量，但它们必然反映在机器人的运动响应中（如机体姿态变化、关节力矩波动、足端接触模式等）。因此，可以利用历史本体观测推断这些隐变量，再把推断

结果作为策略输入的一部分。

HIMLoco 把内部嵌入 z_t 拆解为两部分：显式速度估计 $\hat{v}_t$ 与隐式表征 $z_{imp,t}$ 。显式部 22 武汉科技大学本科毕业论文分通过监督回归与基座线速度真值对齐：

$L_{exp} = \|\hat{v}_t - v_t\|^2 / 2$ (2-40) 隐式部分通过对比学习与下一时刻状态特征对齐，无需人工监督：

$L_{con} = -\log \exp \text{sim}(z_{imp,t}, z_{t+1}) / \tau$

$P_j \exp \text{sim}(z_{imp,t}, z_{-j}) / \tau$ (2-41) 其中 $\text{sim}(\cdot, \cdot)$ 为余弦相似度， τ 为温度系数， z_{t+1} 为同一轨迹下一时刻的正样本特征， z_{-j} 为同一批中其他样本作为负样本特征。该对比目标无需人工监督，便可学习到对地形与扰动敏感的特征。

图 2-12 通过 t-SNE 把内部嵌入降维到二维平面，对比 HIMLoco 与不带对比学习的回归基线两种表征在同地形不同摩擦/速度条件下的分布。可见 HIMLoco 学得表征对地形条件具有清晰可分性，为后续策略基于 z_t 做出风险敏感决策提供了基础。这一性质也是本文奖励调度器之所以能够获得稳定信号的隐性前提：若内部嵌入混杂，难度估计将失去物理意义。

图 2-12 内部嵌入在不同速度与负载条件下的二维可视化示例。不同颜色对应不同工况，聚类分布可用于判断本体历史特征是否携带足够的环境判别信息。

2.7 四足机器人无模型强化学习环境本文沿用业界主流的 Isaac Gym 并行仿真平台[11]。Isaac Gym 把刚体动力学求解、接触检测、关节驱动等关键子系统全部移植到 GPU 上，使单 GPU 可并行运行数千个机器人实例。相比传统 CPU 仿真器 (MuJoCo、PyBullet、RaiSim 等)，Isaac Gym 在样本吞 23 武汉科技大学本科毕业论文量上有 1~2 个数量级的提升，使原本需要数十小时的策略训练缩短至数十分钟，是支撑“快速迭代→域随机化→系统辨识”闭环的关键基础设施。

观测向量 o_t 通常由以下分量构成：

$o_t = [\omega_t, g_t, c_t, q_t - q_0, \dot{q}_t, a_{t-1}] \in \mathbb{R}^{45}$ (2-42) 其中 $\omega_t \in \mathbb{R}^3$ 为基座角速度， $g_t \in \mathbb{R}^3$ 为投影到机体坐标系的重力方向 (替代姿态)， $c_t = [v_{cmd}, x, v_{cmd}, y, \omega_{cmd}, z]^T \in \mathbb{R}^3$ 为命令向量， $q_t, \dot{q}_t \in \mathbb{R}^{12}$ 为关节角与角速度， $a_{t-1} \in \mathbb{R}^{12}$ 为上一控制步动作。该设计避免了直接依赖基座线速度真值 (仿真可获取但实机难测)，从而降低 Sim2Real 鸿沟。

历史观测 $o_{t-H:t-1}$ 以 $H=6$ 步滑动窗口堆叠 (对应 0.12 s 历史)，输入到 HIMLoco 内部嵌入提取器 E_ψ 中。这里 H 的选择需要折中：过短无法包含足端接触切换的完整周期，过长则增加内存与计算压力。

动作 $a_t \in \mathbb{R}^{12}$ 为 12 个关节的目标角偏移，经动作缩放后叠加到默认关节角，再交由底层关节级 PD 控制器以 200 Hz 跟踪：

$\ddot{q}^* = \ddot{q}_0 + \sigma \ddot{a}_t, \tau \ddot{t} = K_p(q^* - q_t) - K_d \dot{q}_t$ (2-43) 其中 K_p, K_d 为关节刚度与阻尼， σ 为动作缩放系数。策略推理频率与奖励统计频率均设为 50 Hz，与 PD 控制频率构成“慢策略+快控制”的双速率结构，既保证策略推理实时性，又充分利用底层执行器的高响应能力。

终止条件包括基座姿态越界 (俯仰或翻滚超过 0.7 rad)、机体高度过低 (接触地面)、超过最大回合长度 (1000 步) 等。终止后环境立即重置到带随机扰动的初始姿态，并重新采样命令与地形参数，从而保证策略不会过拟合特定初始条件。

24 武汉科技大学本科毕业论文图 2-13 仿真地形中的四足机器人连续运动片段。该类批量场景可用于观察策略在不同接触状态与地形风险下的动作稳定性。

2.8 策略模型与本体感知输入本文策略模型沿用 HIMLoco 的“本体观测+历史嵌入”输入设计，可形式化为 $a_t = \pi_\theta(o_t, z_t, c_t, z_t) = E_\psi(o_{t-H:t-1})$ (2-44) 其中 E_ψ 为内部嵌入提取器 (典型实现为一个三层 MLP 或一维卷积)，输出维度 32。 z_t 包含显式速度估计 $\hat{v}_t \in \mathbb{R}^3$ 与隐式表征 $z_{imp,t} \in \mathbb{R}^{29}$ ，分别由 (2-41) 与监督回归损失共同训练。

本体感知信号有三个特点：频率高，能捕捉到接触切换这种瞬态事件；维度低，策略网络规模可控；成本低，低端硬件平台上也能跑。代价是“无前瞻”——策略在足端接触地面之前看不到地形变化。HIMLoco 的内

部模型通过对历史响应建模能在一定程度上弥补这个缺陷：机器人进了粗糙坡面，过去几个控制步的姿态扰动和力矩波动已经明显变大了，内部嵌入会捕捉到这个变化，通过 z_t 把“粗糙”这个隐变量传给策略。

AI 70%

25 武汉科技大学本科毕业论文 2.9 Sim2Real 迁移技术仿真里训出来的策略部署到真实机器人上会遇到系统辨识误差、传感噪声、执行器迟滞和没建模的动力学问题，这些加在一起就是 Sim2Real 鸿沟。来源主要有四个：动力学差异——质量、惯量、连杆长度和电机增益这些参数很难辨识得完全准确；接触建模误差——摩擦模型、地面柔度和足端形状的简化会带来动力学不一致；传感噪声与延迟——IMU 漂移、关节编码器量化和通信延迟会污染观测；执行器特性偏差——电机饱和、温升和传动反隙这些非线性因素在仿真里很难精确刻画。

域随机化 (Domain Randomization) 是缩小 Sim2Real 鸿沟最直接的方法：训练时在仿真环境中对参数 ξ 按某分布 $p(\xi)$ 随机采样，使策略学到对参数变化鲁棒的控制规律：

$\pi^* = \arg \max_{\pi} E_{\xi \sim p(\xi)} \pi(\xi) E_{\pi, M_{\xi}} [P_t(y_{trt} | i)]$ (2-45) 本文沿用 HIMLoco 公开配置，对刚体质量在 $[0.8, 1.2]$ 倍范围采样，对地面摩擦系数在 $[0.2, 1.5]$ 区间采样，对关节 PD 增益在 $\pm 20\%$ 范围扰动，并随机叠加最长 60 ms 的动作延迟与施加在基座上的随机外力推冲。所有随机化在每个回合开始时重新采样。

AI 69%

除域随机化外，HIMLoco 通过内部模型实现“在线自适应”：部署阶段策略实时观测自身响应并通过 z_t 自动调整行为，无需离线再训练。非对称 Actor-Critic 则在训练阶段把特权信息接入 Critic，部署阶段完全丢弃，从而实现“仿真训练用全信息、实机部署用本体信息”。本文方法在 Sim2Real 维度上具备两点优势：奖励调度器仅修改即时奖励计算，不改动网络与传感链路，部署阶段无需任何额外硬件；调度器输入完全来自本体信号，对外感知失效不敏感。

AI 70%

26 武汉科技大学本科毕业论文图 2-14 复杂接触条件下的四足机器人运动片段。连续画面体现了策略在支撑相切换、地形高度变化与姿态修正过程中的响应，可用于辅助讨论 Sim2Real 场景中的接触不确定性。

AI 52%

2.10 多目标奖励与固定权重的局限四足机器人强化学习的奖励函数通常由若干子项加权组成，下表给出本文使用的典型奖励项。

27 武汉科技大学本科毕业论文表 2-6 典型四足机器人强化学习奖励项奖励项数学表达默认权重线速度跟踪 $\exp(-\sigma_v \|v_{xy} - v_{cmd}\|^2)$ 1.0 角速度跟踪 $\exp(-\sigma_\omega (\omega_z - \omega_{cmd})^2)$ 0.5 关节力矩惩罚 $-\| \tau \|_2 / 2 \times 10^{-5}$ 关节加速度惩罚 $-\| \ddot{q} \|_2 / 2 \times 10^{-7}$ 动作平滑惩罚 $-\| a_t - a_{t-1} \|_2 / 2 \times 0.01$ 基座姿态惩罚 $-\| g_{xy} \|_2 / 2 \times 10^{-2}$ 基座高度跟踪 $-(h_t - h_0)^2 / 2 \times 1.0$ 足端腾空高度 $P_i / p_z, \text{air} \cdot f_i - \text{htgt} / 2 \times 1.0$ 足端滑移惩罚 $-P_i / \|v_{xy}\|_2 \cdot I[\text{contact}] - 0.04$ 固定权重相当于在整个空间里用同一套偏好，局部风险变了它也没法跟着调。这个问题在几个典型场景里特别明显：平地上要是稳定项权重给高了，策略会缩手缩脚，速度上限上不去；崎岖地形上要是速度项权重还占大头，触地冲击被放大，跌倒风险也跟着涨；遇到外部扰动，要是没有快速重权的机制，策略的恢复行为又不够积极。

从优化的角度来说，多个奖励项加权求和其实就是在做多目标优化的“标量化”：

$\max_{\pi} \sum_i w_i E_{\pi} [P_t(y_{tri} | i)]$ (2-46) 固定权重 w_i 只对应帕累托前沿上的一个点。这个点最优与否取决于环境分布，而跨地形任务的环境分布变化很大，单个点很容易失配。本文把权重 w_i 改成状态相关函数 $w_i(\hat{d}_t)$ ，相当于让策略沿着帕累托前沿“滑动”，根据风险程度动态选折中点。

AI 66%

2.11 本章小结本章先建立了四足机器人坐标系、正逆运动学和全身动力学的物理基础，给出了 trot 等典型步态的相位定义；然后介绍了 MDP/POMDP、策略梯度、PPO 和 Actor-Critic 网络结构，为后续方法设计提供强化学习支撑；最后梳理了 HIMLoco 内部模型、无模型强化学习环境、Sim2Real 迁移和多目标奖励问题。这些内容共同指向一个结论：本文的奖励调度器应该放在奖励计算端，保持策略主干和传感链路稳定，并通过平滑约束控制对 PPO 优化过程的影响。下一章将在此基础上提出完整方法。

AI 54%

28 武汉科技大学本科毕业论文 3 基于本体感知的自适应奖励调度方法 3.1 方法总体框架第二章已经分析过，固定权重奖励在跨地形任务里有个固有问题：低风险地形需要“效率优先”，高风险地形需要“稳定优先”，同一组权重没法同时满足这两种需求。一个直观的想法是让权重 w_i 变成状态相关的函数 $w_i(s_t)$ ，跟着观测状态

动态调整。但要是直接把权重设计成高维状态的复杂函数，训练会变得很不稳定，工程部署也麻烦。本文的做法是折中一下——先把高维本体观测压缩成一维的“地形难度分数” $\hat{dt} \in [0, 1]$ ，再用这一维信号去驱动多维权重映射，最后用指数平滑和变化率裁剪保证调度平稳。

整个方法管线可以看成一条连续的信息流：从本体观测里提取姿态扰动、力矩变化、接触一致性和动作平滑度四类难度特征，算出原始难度分数 dt ，再用指数平滑得到稳定的 $\hat{dt}$ ，接着用约束型权重映射函数生成中间权重 $\tilde{w}_{i,t}$ ，经过一阶低通和变化率裁剪得到最终权重 $w_{i,t}$ ，最后把这些权重和子奖励合起来得到总奖励 $R_t = \sum w_{i,t} r_{i,t}$ ，再送进 PPO 训练流程。上述流程可进一步写成紧凑的向量形式。令 $f_t = [f_{att} \ f_t \ f_{con} \ f_{act} \ f_{i^T}]^T$, $r_t = [r_{vel} \ r_{rene} \ r_{sta} \ r_{rob} \ r_{i^T}]^T$, (3-1)则奖励调度器可表示为

$\tau \sigma^{-1} N(f_t)$, $\hat{dt} = (1-p)\hat{dt} + p dt$, $\tilde{w}_t = \text{softmax}(\alpha + \beta \hat{dt})$, $w_t = \Pi \Delta (1-\eta)w_{t-1} + \eta \tilde{w}_t$, $R_t = w^T r_t$. (3-2) 其中 $N(\cdot)$ 表示滑动归一化, $\sigma(\cdot)$ 表示 sigmoid 映射, $\Pi \Delta(\cdot)$ 表示满足单步变化率约束的投影算子。该写法把调度器归纳为“归一化-平滑-softmax-投影-内积”五个标准算子，便于实现和复现。

本体观测缓存 IMU/关节/接触难度特征 f_t 难度分数 $dt \rightarrow \hat{dt}$ 权重映射 $\tilde{w}_t \rightarrow w_t$ 奖励合成 $R_t = w^T r_t$ PPO 更新 θ, ϕ 并行仿真环境状态转移子奖励 r_t 图 3-1 本体感知自适应奖励调度流程图。调度器位于奖励计算端，通过本体信号估计地形难度，并将多目标子奖励组合为供 PPO 使用的总奖励。

本文方法的设计遵循三个原则。低耦合——调度器只管奖励计算端，不动策略网络和传感链路，方便即插即用。可解释性——难度特征和权重映射都有明确的物理含义，工程师调试参数和定位故障都比较方便。平稳性——指数平滑加变化率裁剪保证奖励在线 29 武汉科技大学本科毕业论文变化幅度有界，不会把 PPO 的收敛过程搞乱。

3.2 地形难度估计地形难度不是能直接测量的量，但它一定会体现在机器人的本体响应上。本文选了四类本体信号来做难度特征：姿态扰动 $f_{att} \ t$ 用基座角速度的滑动方差来刻画，反映姿态稳不稳；力矩变化 $f_t \ t$ 用关节力矩的滑动方差来描述，反映执行器负载波动大不大；接触一致性 $f_{con} \ t$ 衡量足端实际触地序列和理想 $trot$ 节律差了多少；动作平滑度 $f_{act} \ t$ 用相邻动作差分的滑动方差给出，反映策略输出的稳定程度。表 3-1 将四类特征的数学形式、物理含义与调度作用进行归纳。

表 3-1 地形难度特征的构造方式与物理含义特征计算形式主要含义姿态扰动 $1/W \sqrt{\omega_k^2}$ 躯干角速度越大，说明地形冲击或接触切换越剧烈力矩变化 $1/W \sqrt{\tau_k - \tau}$ 执行器负载波动越大，说明足地作用更不稳定接触一致性 $1/W \sqrt{|\pi_{i,k} - \hat{c}_{trot} i,k|}$ 实际触地序列偏离 $trot$ 节律时，步态稳定性下降动作平滑度 $1/W \sqrt{a_k - a_{k-1}}$ 策略输出突变越明显，越可能处于恢复或避障状态具体地：

$f_{att} \ t = 1/W \sqrt{\sum_{k=t-W+1}^t \omega_k^2}$, $f_t \ t = 1/W \sqrt{\sum_{k=t-W+1}^t \tau_k - \tau}$, (3-3) $f_{con} \ t = 1/W \sqrt{\sum_{k=t-W+1}^t | \pi_{i,k} - \hat{c}_{trot} i,k |}$, $f_{act} \ t = 1/W \sqrt{\sum_{k=t-W+1}^t a_k - a_{k-1}}$, (3-4) 其中 W 为时间窗长度， τ 为窗内力矩均值。本文取 $W = 12$ ，对应 0.24 s 窗。

这几个特征量纲不一样，直接加在一起会出现尺度不平衡的问题。所以用滑动均值-方差做归一化：

$\tilde{f}(j)t = \text{clip} \ f(j)t - \mu(j)t \ \sigma(j)t + \epsilon, -3, 3, j \in \{att, \tau, con, act\}$, (3-5) 其中 $\mu(j)t, \sigma(j)t$ 由滑动窗（典型长度 1000 步）动态更新。归一化结果再通过 sigmoid 映射到 $[0, 1]$ 区间：

$\tilde{f}(j)t = 1 / (1 + \exp(-\tilde{f}(j)t))$. (3-6) 30 武汉科技大学本科毕业论文最终难度分数定义为各特征的凸组合：

$dt = \sum_j u_j \tilde{f}(j)t, \sum_j u_j = 1, u_j \geq 0$, (3-7) 本文取 $u_{att} = 0.35, u_{\tau} = 0.25, u_{con} = 0.25, u_{act} = 0.15$ 。考虑到瞬时难度分数会随触地切换出现高频波动，进一步以指数平滑得到稳定难度估计：

$\hat{dt} = (1-p)\hat{dt} + p dt$, (3-8) 其中 $p \in [0, 1]$ 为平滑系数。本文取 $p = 0.1$ 。

3.3 奖励权重动态映射设奖励项集合 $\{r_{vel} \ t, r_{ene} \ t, r_{sta} \ t, r_{rob} \ t\}$ 分别对应速度跟踪、能耗约束、姿态稳定与抗扰恢复四类目标。直接以线性映射 $w_i = \alpha_i + \beta_i \hat{dt}$ 容易出现负值或超界，且各权重之间不满足凸约束。本文采用 softmax 形式构造中间权重，自动保证非负与归一：

$\tilde{w}_{i,t} = \exp(\alpha_i + \beta_i \hat{dt}) / \sum_j \exp(\alpha_j + \beta_j \hat{dt}), \sum_i \tilde{w}_{i,t} = 1$. (3-9) 其中 α_i 控制无风险时的基准权重， β_i 控制随风险变化

的趋势： $\beta_i > 0$ 表示该项随风险升高而权重增加， $\beta_i < 0$ 表示反之。本文取 $\alpha = [1.0, 0.6, 0.4, 0.2]$, $\beta = [-0.4, -0.6, 1.2, 1.0]$, (3-10) 对应“低风险时偏向速度与能效，高风险时偏向稳定与恢复”。

为避免奖励权重在相邻步之间剧烈变化进而扰乱 PPO 优势估计，引入一阶低通滤波：

$w_{i,t} = (1-\eta)w_{i,t-1} + \eta \tilde{w}_{i,t}$, (3-11) 再叠加变化率裁剪：

$w_{i,t} = \text{clip}(w_{i,t}, w_{i,t-1} - \Delta, w_{i,t-1} + \Delta)$. (3-12) 本文取 $\eta = 0.1$, $\Delta = 0.02$ 。最终总奖励：

$R_t = \sum_i w_{i,t} r_{i,t}$, (3-13) 图 3-2 给出一段典型训练片段中权重轨迹示意。可见随着难度分数 $\hat{d}_t$ 在低风险与高风险之间切换，速度项权重 w_{vel} 与稳定项权重 w_{sta} 呈现互补变化：低风险时速度项主导，高风险时稳定项主导。

该“互补滑动”是本文方法实现“场景相关偏好”的可视化证据。

AI 69%

31 武汉科技大学本科毕业论文图 3-2 训练过程中关键状态量与奖励相关量的曲线示例。多条时序曲线可用于观察策略收敛、控制波动与难度响应之间的关系。

3.4 训练与推理过程训练阶段沿用 HIMLoco 的“内部模型优化+ PPO 更新”交替策略，在此基础上插入奖励调度器。具体训练流程如算法 3-2 所示。

32 武汉科技大学本科毕业论文表 3-2 自适应奖励调度训练流程伪代码输入：策略 π_θ 、价值 V_ϕ 、内部模型 E_ψ 、调度参数 $(\alpha, \beta, \rho, \eta, \Delta)$ 1: for 迭代 $k = 0, 1, 2, \dots$ do 2: for 控制步 $t = 1, \dots, T$ do 3: 各并行环境采样动作 $a_t \sim \pi_\theta(\cdot | o_t, z_t, c_t)$ 4: 仿真器演化得到下一状态与子奖励 r_t 5: 提取难度特征并计算 $\hat{d}_t$ 6: 由 (3-9)-(3-12) 计算权重 $w_{i,t}$ 并合成 R_t 7: end for 8: 计算 GAE 优势与目标回报，更新 θ, ϕ 与 E_ψ 9: end for 与表 3-2 对应，图 3-3 给出本文方法的训练流程图。该流程与传统 PPO 的差异在于：

环境交互后并不直接把子奖励求和，而是先经过难度估计与权重调度，再将合成奖励写入轨迹缓冲池。

开始初始化网络 $\pi_\theta, V_\phi, E_\psi$ 并行采样 $a_t \sim \pi_\theta$ 仿真推进 $st \rightarrow st+1$ 特征提取 ft 权重调度 $\hat{d}_t, w_t$ 奖励合成 $R_t = \sum_i w_{i,t} r_{i,t}$ 轨迹缓冲 τ 1: T GAE 与回报 $\hat{A}_t, \hat{R}_t$ PPO 更新 θ, ϕ 内部模型更新 ψ 达到迭代数？结束是否图 3-3 融合 PPO、内部模型与自适应奖励调度的训练流程图。奖励调度器插入环境交互与轨迹入池之间，不改变 Actor-Critic 主网络结构。

AI 66%

推理阶段奖励计算停止，但调度器中的特征提取与平滑机制仍可在线运行，作为“风险监测器”输出 $\hat{d}_t$ 。该信号可被上层任务管理模块或安全监控模块用于触发降速、停机、报警等行为。实际部署时，若仅追求最低改造成本，可在推理阶段彻底丢弃调度器，由训练得到的策略本身承担跨地形适配；若进一步追求在线安全性，则保留调度器作为监控通路。

AI 70%

3.5 速度-地形双课程融合方法单一难度课程在跨地形任务中存在两个问题：若仅按地形难度推进，策略可能在低速命令下提前“通关”而未学到高速场景；若仅按速度命令推进，策略可能在高速下因地形过难而频繁失败，训练曲线长期停滞。为此本文采用速度-地形双课程融合方案。

33 武汉科技大学本科毕业论文设速度等级集合 $V = \{v_1, \dots, v_K\}$ （如 $0.5 \sim 4.0$ m/s 步长 0.5）、地形等级集合 $T = \{T_1, \dots, T_M\}$ （按粗糙度、坡度、台阶高度分级）。每个并行环境维护当前所在的速度-地形二维等级 (k, m) ，并依据近期跟踪误差 $\bar{e}_v$ 与跌倒比例 $\bar{p}_f$ 决定是否升降级：

$(k, m) \leftarrow (k, \min(m+1, M))$, $\bar{e}_v < \bar{e}_v^{\text{up}}$ 且 $\bar{p}_f < \bar{e}_f^{\text{up}}$, $(\min(k+1, K), m)$, $\bar{e}_v < \bar{e}_v^{\text{up}}$ 且 $m = M$, $(k, \max(m-1, 1))$, $\bar{p}_f > \bar{e}_f^{\text{dn}}$, (k, m) , 其他. (3-14) 即优先在当前速度等级上推进地形难度，地形封顶后再提升速度，跌倒率超阈值时回退地形等级。该规则避免速度与地形同时升级造成的训练崩溃，又保证两个维度都能逐步覆盖目标范围。

图 3-4 进一步给出双课程推进关系。训练初期位于低速度、低地形难度区域；当通过率和速度跟踪误差满足阈值后，先沿地形维度上升，随后在地形封顶处提升速度等级；

AI 69%

若跌倒率升高，则沿地形维度回退。

$v_1, T_1, v_1, T_2, v_1, T_3, v_2, T_1, v_2, T_2, v_2, T_3, v_3, T_1, v_3, T_2, v_3, T_3$ 跌倒回退横向：速度等级 v_k 提升 纵向：地形难度 T_m 提升图 3-4 速度-地形双课程推进示意图。实线表示满足阈值后的升级方向，虚线表示跌倒率过高时的安全回退

方向。

34 武汉科技大学本科毕业论文图 3-5 不同训练配置下的性能曲线示例。曲线随迭代上升并逐渐收敛，可用于辅助说明课程训练对策略性能提升过程的影响。

3.6 平坦地形下的运动控制任务平坦地形是验证基础控制能力的关键场景，也是后续课程升级的起点。该任务设定为：机器人在水平地面上响应任意(vcmd x, vcmd y, wcmd z)命令，命令在每回合起始按均匀分布采样：

AI 66%

vcmd x~ U[-1.0,3.5]m/s, vcmd y~ U[-0.6,0.6]m/s, wcmd z~ U[-1.0,1.0]rad/s.(3-15)35 武汉科技大学本科毕业论文要求策略在保持稳定 trot 步态的同时跟踪命令并最小化能耗。平坦地形虽不涉及复杂接触，但对策略的速度跟踪精度、步态周期性与能效提出较高要求。

平坦地形任务的奖励通常以速度跟踪项为主、稳定与平滑项为辅：

AI 69%

$r_{flat} = w_v \exp(-\sigma_v // v_{xy} t - v_{cmd} t // 2) + w_w \exp(-\sigma_w (\omega_z t - w_{cmd} t)^2$

$- w_t // t // 2 - w_a // a_t - a_{t-1} // 2 - w_g // g_{xy} t // 2)。(3-16)$ 其中前两项鼓励命令跟踪，后三项分别抑制能耗、动作抖振与姿态倾斜。平坦地形结果常被用于评估策略的“理论上限”：策略若在平坦地形上达到接近物理极限的速度与能效，并能稳定保持 trot 节律，则可作为后续地形升级的可靠基础。

本文方法在平坦地形上若能保持与基线相当甚至更优的表现，则说明动态调度未以牺牲基础能力为代价换取跨地形稳定性，这正是奖励调度方法工程价值的关键判据之一。这一“基础能力守恒”要求与“跨地形增强”要求共同构成本文方法的双重验证标准。

已有多篇四足机器人控制论文都将平坦地形视为策略学习的基础阶段。本文采用相同思想，把平坦地形任务拆分为静态站立、低速直行、中速 trot、侧向移动与原地转向五个子阶段。阶段一仅要求机器人保持基座高度与姿态稳定，防止策略在初期探索中快速跌倒；阶段二引入小幅前向速度命令，训练足端周期触地；阶段三扩大 vcmd x 区间，使 trot 步态逐渐稳定；阶段四加入 vcmd y，考察横向移动能力；阶段五加入 wcmd z，形成完整三维速度命令跟踪任务。

表 3-3 平坦地形运动控制任务的阶段化训练设置

阶段	训练目标	命令空间扩展判定指标
1 静态站立	vx=vy=wz=0 姿态角、基座高度	2 低速直行 vcmd x>0 前向速度误差
3 中速 trot	扩大 vcmd x 上界 接触周期、跌倒率	4 侧向移动 加入 vcmd y 横向跟踪误差
5 原地转向	加入 wcmd z 偏航角速度误差	阶段化训练并不意味着使用多个策略，而是在同一策略训练过程中逐步扩展命令分布：

AI 64%

$C_k = [v_{min} x, k, v_{max} x, k] \times [v_{min} y, k, v_{max} y, k] \times [\omega_{min} z, k, \omega_{max} z, k]。(3-17)$ 若最近 N 个回合的平均跟踪误差低于阈值且跌倒率低于阈值，则进入下一命令集合 C_{k+1} 。这一机制使策略先学会“如何不摔倒”，再学习“如何跑得快”，与速度-地形双课程中的安全优先原则一致。

平坦地形奖励以速度跟踪为主，复杂地形奖励则需要更强调姿态与接触稳定。二者并非彼此矛盾，而是同一多目标奖励在不同风险水平下的不同投影。以速度项 r_v 、稳定 36 武汉科技大学本科毕业论文项 r_s 、能耗项 r_e 为例，平坦地形的权重可近似设置为 $w_{flat} = [0.55, 0.25, 0.20]$ 。(3-18)而高风险地形可调整为 $w_{rough} = [0.32, 0.48, 0.20]$ 。(3-19)本文自适应调度器正是把这种人工分场景调参过程在线化，使权重在平坦与崎岖之间连续过渡，而非人为切换多个控制器。

AI 70%

3.7 复杂度与稳定性分析调度器只包含小规模向量运算：四类特征统计为 $O(W)$ 滑动窗求和（增量更新可降至 $O(1)$ ）；难度合成为 $O(m)$ ， $m=4$ 为子项数；权重映射为一次 softmax 与一次 clip，复杂度同样 $O(m)$ 。整体推理开销远小于策略网络前向计算（ $O(d^2 h)$ ， dh 为隐层宽度），可忽略。在 50 Hz 控制回路中，调度器单步耗时约 $5\mu s$ 量级。

为解释调度器为何不会破坏 PPO 的收敛行为，可从奖励扰动角度分析。设固定权重总奖励为 $R_0 t = \sum_i w_0 i r_{i,t}$ ，调度后总奖励为 $R_t = \sum_i w_i r_{i,t}$ ， $tr_i, t = R_0 t + \sum_i (w_i, t - w_0 i) r_{i,t}$ 。

由(3-12)知 $|w_i, t - w_i, t-1| \leq \Delta$ ；又因子奖励项 $|r_{i,t}| \leq M_r$ 有界，故权重扰动引入的奖励差分 $|R_t - R_{t-1}|$ 在最坏情况下被 $|R_t - R_{t-1}| \leq \sum_i |w_i, t - w_i, t-1| |r_{i,t}| + \sum_i |w_i, t-1| |r_{i,t} - r_{i,t-1}| \leq m \Delta M_r + // R_0 // \text{Lip}(3-20)$ 所限制，其中

//R0//Lip 为固定奖励本身的 Lipschitz 常数。这意味着调度引入的额外扰动为 $O(m\Delta Mr)$ ，与 Δ 线性相关。当 $\Delta = 0.02$, $m = 4$, $Mr \leq 5$ 时，扰动上界约 0.4，远小于固定奖励本身的波动，因而不会显著改变优势估计的统计特性。

AI 52%

实际部署时有两类异常情况值得关注。难度评分偏高会使系统过早地向稳定项倾斜，速度收益跟着下降——解决办法是对速度权重设下限 $w_{vel} \geq w_{min} \text{ vel} = 0.2$ ，避免策略缩手缩脚。反过来，难度评分偏低时系统可能偏激进，这时如果姿态波动连续 5 步超过阈值，就触发“安全增权”：把稳定项和恢复项的权重各乘 1.5 倍并保持 50 步。这些保护手段不改网络结构，但对于异常场景的鲁棒性提升很明显。

AI 51%

实际部署时实时性和故障回退同样不能忽视。要是碰到观测丢帧、IMU 出问题或者控制延迟突然变大，调度器就退回预设静态权重，保证系统行为还能预测。工业场景里“可控退化”往往比“性能最优”更有工程价值，原因就在这里。

AI 78%

37 武汉科技大学本科毕业论文 3.8 参数设置与工程实现细节表 3-4 自适应奖励调度方法的关键超参数与推荐范围参数含义推荐范围 W 难度特征滑动窗长度（控制步）8~20 ρ 难度分数指数平滑系数 0.05~0.20 η 权重一阶低通系数 0.05~0.20 Δ 权重单步变化率上限 0.01~0.05 u 难度特征融合权重凸组合 α 基准权重对数 0~2 β 风险敏感系数 -1~2 w_{min} 安全权重下限 0.1~0.3 在工程实现中，调度器部署于奖励计算端，输入来自控制回路中已有的本体状态缓存，不新增传感链路。难度特征统计窗口长度 W 过短易受瞬时噪声影响，过长则会降低响应速度，本文 $W = 12$ 较为均衡。特征归一化采用滑动均值与方差更新，既适应训练初期分布漂移，也避免后期统计量剧烈震荡。

AI 60%

映射参数 α, β 建议先用人工先验初始化（满足“低风险效率优先、高风险稳定优先”原则），再通过小规模网格搜索微调。本文将全部调度超参数纳入实验配置文件并固定随机种子，保证对比实验可重复。代码层面调度器仅~80 行 Python，与 HIMLoco 主代码完全解耦，便于二次开发。

AI 67%

3.9 本章小结本章完整给出了自适应奖励调度方法。从总体框架看，方法通过“特征提取-难度合成-权重映射-平滑约束-异常回退”五段管线把高维本体观测转化为低维奖励权重调整信号；从理论分析看，方法引入的奖励扰动有界，不会破坏 PPO 收敛；从工程实现看，方法仅需~80 行代码、不增加传感器、不修改主干策略，可即插即用集成到现有 HIMLoco 控制管线中。配合双课程训练与平坦地形基础任务，本方法在“跨地形增强”与“基础能力守恒”两个维度上具有可验证的设计闭环。

38 武汉科技大学本科毕业论文 4 基于课程学习的训练优化方法前文通过强化学习实现了四足机器人基本运动控制，但机器人需应对的环境复杂多变，且对运动性能（高速、高敏捷、跨地形）有较高要求。若在训练初期直接以大范围速度指令和复杂地形进行随机化采样，智能体在策略不成熟的早期阶段难以从困难样本中稳定学习，容易导致训练失败或收敛缓慢。本章引入课程学习（Curriculum Learning）方法，分别设计速度指令课程与地形适应课程，使机器人由易到难地逐步适应高速运动目标与复杂地形环境，并进一步将两种课程融合，在保证训练稳定性的前提下提升强化学习的采样效率与综合运动能力。

AI 70%

4.1 课程学习理论基础对于一个机器学习过程，将复杂任务按照由易到难的规律进行分解，可以使神经网络更快地学到有效特征，也更容易攻克困难任务目标。在强化学习训练中，同样可以依照一定的难易顺序，先采样简单数据进行拟合，待训练效果达到期望水平后再逐步引入复杂样本。课程学习通过权重区分不同难度样本的采样频率：在训练早期给简单样本赋予高权重，使其以更大概率被采样和学习；随着训练推进，逐渐提高困难样本的权重，最终使模型掌握高难度特征。

在课程学习中，对于表示训练样本集的随机变量 z ，其目标学习到的概率分布映射函数为 $P(z)$ 。设进行到第 λ 步（ $\lambda \in [0, 1]$ ， λ 越大则优化越困难，是一个单调递增序列）时的样本权重为 $W\lambda(z)$ ，则第 λ 步时 z 的训练分布 $Q\lambda(z)$ 为：

$Q\lambda(z) = W\lambda(z)P(z), \forall z$ 。(4-1) 当最终过程即 $\lambda = 1$ 时，满足 $\int Q1(z)dz = 1$ ，即 $Q1(z) = P(z) \forall z$ ，表示训练结束时训练分布等于目标分布。如果这些分布的熵随 λ 的增加而增加，则该分布序列 $Q\lambda$ 构成一个课程：

$H(Q\lambda) < H(Q\lambda + \epsilon), \forall \epsilon > 0, (4-2)$ 其中 H 表示熵, 熵的增加意味着分布变得更加均匀。同时, 样本权重单调递增:

$W\lambda + \epsilon(z) \geq W\lambda(z), \forall z, \forall \epsilon > 0, (4-3)$ 课程学习的关键是通过“难度测量器”作为分级函数对每个任务给出学习优先程度, 同时通过“训练调度器”决定该难度下的采样规则。这种“难度测量器+训练调度器”的架构是课程学习中最常见的基本模式, 如图 4-1 所示。

39 武汉科技大学本科毕业论文图 4-1 课程学习基本框架。难度测量器对任务进行分级评估, 训练调度器根据当前难度决定样本的采样概率与分布范围。

通过课程学习的方法, 在训练四足机器人强化学习策略时, 可以从原先的基本行走技能出发, 逐步拓展出更高难度的运动任务。本章从四足机器人运动速度以及地形适应能力两个维度分别设计课程策略, 并进一步融合两种课程以协同提升机动性与环境适应性。

4.2 速度指令课程设计与验证速度指令分布与课程动机通过强化学习实现高速运动需要让智能体适应宽范围的速度指令并稳定学习到优秀策略。在每个训练回合中, 纵向线速度 v_{cmd} 与横摆角速度 ω_{cmd} 根据概率分布进行采样。在没有课程学习的情况下, 采样分布在训练过程中保持不变:

$p_{k+1} v_{x, \omega_z}(\cdot) \leftarrow p_k v_{x, \omega_z}(\cdot), (4-4)$ 然而, 若训练初期速度指令从一个较大的分布中均匀采样, 高速指令过多的回合因策略尚未成熟而难以获得有效奖励, 智能体将因策略更新混乱而训练失败。因此, 需要采用课程学习让速度指令分布随训练进程逐步扩展:

$p_{k+1} v_{x, \omega_z}(\cdot) \leftarrow f \cdot p_k v_{x, \omega_z}(\cdot), k, (4-5)$ 其中 f 为由训练进程 k 决定的分布更新规则。

独立分布与联合分布更新考虑纵向线速度 v_x 和横摆角速度 ω_z 的独立分布 $p_{vx}(\cdot)$ 和 $p_{\omega_z}(\cdot)$, 采样过程为 $p_{v_x, \omega_z}(\cdot) = p_{v_x}(\cdot) p_{\omega_z}(\cdot)$ 。为线速度与角速度分别指定单独的更新规则 f_v 、 f_ω :

$p_{k+1} v_x(\cdot) \leftarrow f_v \cdot p_k v_x(\cdot), r_{v_x}, p_{k+1} \omega_z(\cdot) \leftarrow f_\omega \cdot p_k \omega_z(\cdot), r_{\omega_z} (4-6)$ 40 武汉科技大学本科毕业论文这种速度独立分布自适应课程的更新过程如图 4-2 所示。然而, 独立采样 v_x 和 ω_z 会导致训练后期采样到复合最大速度的概率与采样到单一最大线速度/角速度的概率相同。由于高速下的离心力效应, 进行高速急转弯比单独快速奔跑或单独急转弯困难得多。

若智能体无法在复合速度下跟踪任务目标, 课程只会单独增加单项速度的难度, 导致复合指令愈发困难而不被采样到。

图 4-2 速度独立分布更新过程。线速度与角速度分别独立扩展, 训练后期难以有效覆盖高速高转速耦合指令区域。

为实现更敏捷的综合运动能力, 本章采用速度联合分布自适应课程:

$p_{k+1} v_{x, \omega_z}(\cdot) \leftarrow f \cdot p_k v_{x, \omega_z}(\cdot), r_{v_x}, r_{\omega_z} (4-7)$ 联合分布以 $[0 \text{ m/s}, 0 \text{ rad/s}]$ 为中心、分辨率为 $[0.5 \text{ m/s}, 0.5 \text{ rad/s}]$ 的离散网格区域表示。初始化时, $p_{v_x, \omega_z}(\cdot)$ 在 $v_x \in [-0.5, 0.5] \text{ m/s}$ 、 $\omega_z \in [-0.5, 0.5] \text{ rad/s}$ 范围内取均匀概率分布。

训练调度器通过成功阈值 $\gamma \in [0, 1]$ 实现更新判断: 每当智能体在当前指令网格区域上的跟踪奖励达到阈值 γ , 便将邻近网格区域加入到采样分布中。其更新过程如图 4-3 所示。

41 武汉科技大学本科毕业论文图 4-3 速度联合分布更新过程。线速度与角速度以联合概率密度方式同步扩展, 确保高速高转速耦合指令区域被充分覆盖。

尽管独立分布更新规则可以更快到达单一高速指令范围, 但为获得更好的运动敏捷性以及更新安全性, 本研究采用速度联合分布自适应课程方案。

速度课程实验验证添加速度指令课程后, 速度采样区域随训练进程逐步扩展。如图 4-4 所示, 在约 12000 次迭代后采样进入极限范围, 覆盖了 $[-10 \text{ m/s}, 10 \text{ m/s}]$ 范围的 25%, 训练过程中最大采样线速度与角速度达到 5.0 m/s 和 5.0 rad/s 。在速度范围接近机器人运动能力极限时, 奖励函数因回合提前终止、机身稳定性下降等因素而出现一定波动, 这反映了控制指令难度的持续升级。

AI 70%

图 4-4 速度课程训练过程中的采样区域扩展（左）与奖励函数变化（右）。采样区域随训练逐步扩大，奖励在极限区域出现合理波动。

在极限速度性能方面，图 4-5 给出了课程训练后的最大纵向速度测试结果。四足机器人在经过速度指令课程学习后，最大稳定跟踪线速度达到 6.2 m/s。

AI 66%

42 武汉科技大学本科毕业论文图 4-5 最大纵向速度测试。经过速度课程训练后，机器人最大稳定跟踪线速度达到 6.2 m/s，展现出突出的高速运动潜力。

为衡量该速度指标的水平，采用弗劳德数（Froude number）进行对比。弗劳德数通过最高速度下的向心力与重力之比表示动物的运动能力：

$Fr = mv^2 / mgl$ (4-8) 根据仿真环境下得到的最大线速度 6.2 m/s，腿长 $l = 0.4$ m，计算得到理论最大速度下的弗劳德数为 9.8。表 4-1 给出了与其他典型四足机器人平台的弗劳德数对比，可见本模型的奔跑潜力在同规格平台中处于领先水平。

AI 70%

表 4-1 四足机器人弗劳德数对比

四足机器人	弗劳德数	速度 (m/s)	腿长 (m)	Go1 (本研究)
MiniCheetah	5.1	3.9	0.3	9.8
BlackPanther	8.5	5.0	0.3	6.2
A1	2.8	3.3	0.4	0.4
ANYmal	0.5	1.5	0.5	

在横摆角速度方面，图 4-6 给出了最大横摆角速度测试结果。四足机器人在经过课程训练后最高可以跟踪到 9 rad/s 的转向指令。但在高转速下，由于腿足式结构难以保持运动连续性，切换支撑相的瞬间会丢失一部分角速度，导致约 25% 的速度损失。尽管如此，转体过程中机身姿态相对稳定。

AI 64%

图 4-6 最大横摆角速度测试。课程训练后机器人最高可跟踪 9 rad/s 转向指令，高转速下存在约 25% 的切换速度损失。

43 武汉科技大学本科毕业论文由于速度课程采用联合概率分布，训练不仅获得单项最大速度性能的提升，在高速高转速复合指令情况下的综合运动敏捷性也获得了相应提升。图 4-7 展示了每个 [0.5 m/s, 0.5 rad/s] 分辨率区间内不同线速度所能保持的角速度跟踪情况。

AI 70%

图 4-7 线速度-角速度覆盖区域热力图。每个网格单元表示在该速度分辨率区间内角速度跟踪的成功程度，暖色区域表示高速高转向复合指令的稳定覆盖。

4.3 地形课程设计与验证训练地形构建与难度分级四足机器人的核心应用优势在于足式行走的越障与跨地形能力，因此强化学习训练需要考虑策略针对多样化地形的学习能力。本章在仿真环境中构建了多种典型地形，如图 4-8 所示，包括光滑坡面、凹凸坡面、上楼梯、下楼梯、随机台阶与平地共六类。为提高地形生成效率并减小并行环境的运算负担，所有环境共用 50 个地形区块，每个地形区块随机获得一种地形形状，并在规格参数上加以随机化处理以增强学习鲁棒性。

AI 69%

图 4-8 训练地形分类。从左至右、从上至下依次为：光滑坡面、凹凸坡面、上楼梯、下楼梯、随机台阶与平地。

每种地形按照参数化难度等级进行设置，如表 4-2 所示。难度等级 $k \in [0, 1]$ 控制各 44 武汉科技大学本科毕业论文类型的核心几何参数：坡道的斜率、楼梯的单级高度、随机台阶的最大高度均随 k 线性变化。地形类型分配占比在训练中保持固定，以保证各类地形均有充分的采样机会。

表 4-2 地形难度等级设置

地形类型	难度设置分配占比
光滑坡面	$i \text{ 坡度} = k \times 0.4$
凹凸坡面	$i \text{ 坡度} = k \times 0.4$
上楼梯	$h \text{ 单级} = 0.05 + (k > 0.1) \times 0.05$
下楼梯	$h \text{ 单级} = 0.05 + k \times 0.18$
随机台阶	$h \text{ 最大} = 0.05 + k \times 0.2$
平地	—0.20

本体感受下的地形感知方法在仅依赖本体感受传感器（IMU、关节编码器）的条件下，四足机器人无法直接获取路面几何信息。前文采用的域随机化与教师-学生网络结构为解决该问题提供了基础：

AI 61%

教师网络在仿真中以特权观测形式直接获取地形真值信息，学生网络通过域适应学习模仿教师的地形感知能力，而部署阶段学生网络仅依靠本体感受状态运行。在本章的地形课程训练中，将路面高度信息纳入特权观测空间，使教师网络能够利用地形信息进行精准控制，学生网络则通过历史观测序列间接推断地形特征。

AI 68%

图 4-9 通过特权观测空间感知地形。教师网络在仿真中获取地形高度真值，学生网络通过域适应从历史本体观测中学习隐式地形表征。

对于行走中的四足机器人而言，最关键的是判断下一步落足点是否安全。本章进一步设计足端临近点高度估计方法：为每条腿的足端周围构建一组 $m \times n$ 的矩阵 M 表示足端临近点，通过设置分辨率 $[r_x, r_y]$ 与矩阵维度控制感知信息的密度与容量。对于第 k 45 武汉科技大学本科毕业论文条腿的足端位置 pf, k ，其第 (i, j) 个足端临近点在世界坐标系下的位置为：

$$p'f, k(i, j) = \begin{matrix} qyaw // qyaw // \\ \cdot pf, k(i, j) \cdot qyaw // qyaw // \\ -1 + pf, k, (4-9) \end{matrix}$$
 其中 $qyaw$ 为只保留俯仰姿态角（通过哈达玛积剔除横滚分量）的机体姿态四元数，以保证足端临近点阵在转向过程中与世界坐标系方向一致。

AI 70%

图 4-10 特权空间感知足端临近点高度信息。每条腿足端周围以 $m \times n$ 点阵感知临近区域的高度变化，为策略提供落足安全性的隐式判断依据。

上述足端附近点信息使四足机器人能够感知落足区域的高度变化，为在地形变化时做出针对性的抬腿与步幅调整提供了信息基础。在本章实验中，足端附近点阵在 x - y 轴上的分辨率设置为 $[0.05 \text{ m}, 0.05 \text{ m}]$ ，矩阵维度为 9×5 。

地形课程策略与验证地形的难度等级可以自然地作为课程学习的依据。地形初始化时，以列为单位区分地形类型，以行为单位区分地形难度等级（共 10 级）。每个并行环境中的智能体只在前列所对应的固定地形种类中训练。地形课程的更新规则基于任务完成程度：若智能体在第 t 回合于等级 nt 的地形上完成了超过一半的期望位移，则在 $t+1$ 回合提升至等级 $nt+1$ ；若完成不到 $1/3$ 期望位移，则回退至 $nt-1$ ：

$$nt+1 = \begin{matrix} nt+1, s > 1/2 \text{ s 预期}, nt, 1/3 \text{ s 预期} \leq s \leq 1/2 \text{ s 预期}, nt-1, s < 1/3 \text{ s 预期} \end{matrix} \quad (4-10)$$

为保证机器人在遇到障碍时能够将腿抬高至不被阻挡的高度，在奖励函数中额外设 46 武汉科技大学本科毕业论文置跨越障碍奖励项：

$$R_{\text{跨越障碍}} = \begin{matrix} p_{\max} f, k(i > 4, j) - h_{\text{障碍}}, p_{\max} f, k(i, j) > h_{\text{障碍}}, v > 0, p_{\max} f, k(i < 4, j) - h_{\text{障碍}}, \\ p_{\max} f, k(i, j) > h_{\text{障碍}}, v < 0, 0, \text{其他} \end{matrix} \quad (4-11)$$
 在不部署速度指令课程的情况下，单独进行地形适应课程训练。图 4-11 给出了各类地形难度等级的训练收敛曲线。经过 4000 次迭代后，所有地形的训练程度收敛在难度 5 附近（为预设最大难度 10 的一半）。其中，上楼梯与跨越障碍两种动作对本体感受下的四足机器人而言难于做出正确决策，学习速度较慢；下楼梯过程可能因跌倒带来的远距离位移被误判为地形适应成功而难度上升偏快，但所有地形等级最终趋于稳定，达到训练极限。

AI 69%

图 4-11 地形难度等级训练收敛曲线。在 4000 次迭代后各类地形难度收敛至 5 级附近，模型达到稳定训练状态。

在地形适应课程训练后，四足机器人的跨越地形能力如图 4-12 所示。机器人可以攀爬 12 cm 高度的台阶、攀登约 45° 的坡道，以及跨越 18 cm 高度的障碍物。这表明课程学习可以在不依赖外部视觉传感器的前提下，仅通过本体感受与特权观测的教师-学生结构，显著增强策略的地形适应能力。

AI 62%

47 武汉科技大学本科毕业论文图 4-12 四足机器人跨越地形能力验证。课程训练后机器人可爬上 12 cm 台阶、攀登 45° 坡道、跨越 18 cm 障碍物。

4.4 速度-地形双课程融合方法双课程冲突分析前文分别通过速度课程和地形课程增强了策略对宽范围速度指令和多样化地形的适应能力。然而，若直接将两种课程同时部署，二者之间会产生相互制约。图 4-13 给出了速度-地形课程同时训练的效果。可以看出，速度课程的过快更新导致智能体在高难度地形下频繁收到无法实现的高速指令，从而没有机会触发地形升级条件；反之，地形课程对高速的抑制也拖累了速度采样区域的扩展。这导致两种课程的效果均不及单独训练。

AI 68%

图 4-13 速度-地形课程同时训练效果。速度课程过快更新抑制了地形学习进程，二者之间相互制约导致各自效果均不及单独训练。

基于地形类型的速度采样截断为解决上述冲突，本章提出基于地形类型的速度采样范围截断策略。核心思

想是:

复杂地形（楼梯、台阶等）以运动稳定性为优先目标，对速度要求较低，因此限制其速度指令上限；平坦地形则保留高速度上限以充分发挥机动性。具体而言，对于不同地形 48 武汉科技大学本科毕业论文类型设置不同的线速度与角速度采样范围，如表 4-3 所示。

表 4-3 不同地形的速度采样范围地形类型 线速度范围 (m/s) 角速度范围 (rad/s) 光滑坡面[1.5, 3.0][1.5, 3.0] 凹凸坡面 [1.5, 3.0][1.5, 3.0] 上楼梯 [1.0, 2.0][1.0, 2.0] 下楼梯 [1.0, 2.0][1.0, 2.0] 随机台阶 [1.5, 3.0][1.5, 3.0] 平地 [0.5, 5.0][0.5, 5.0]对于不同地形下不同难度的采样范围，采用内插截断规则：

$V_{max-n}=V_{max}-0-(1-k)(V_{max}-0-V_{max}-10)$, $W_{max-n}=W_{max}-0-(1-k)(W_{max}-0-W_{max}-10)$, (4-12) 其中 k 为当前难度等级参数。图 4-14 给出了加入速度截断规则后双课程融合训练的结果。

图 4-14 速度-地形双课程融合训练结果。左图为加入速度截断后的采样区域扩展（在 11000 回合后覆盖指令范围的 50%），右图为地形难度等级收敛（大部分地形收敛至 6 级，高于单一课程的 5 级）。

可以看出，在 11000 个回合后速度指令区域线性增长至 0.5 倍满范围，说明训练覆盖了截断后指令范围的一半，速度指令范围仍有提高空间。地形适应方面，智能体不再因为速度提升过快而无法应对复杂地形，反而能在小范围内提高速度的同时更好地适应地形。大部分地形最终收敛至 6 级附近，略高于单一地形课程收敛到的 5 级难度。这表明速度课程与地形课程在合理约束下可以协同工作，在不牺牲地形适应能力的前提下有效扩展速度性能。

49 武汉科技大学本科毕业论文 4.5 本章小结本章围绕课程学习在四足机器人强化学习训练中的应用展开。首先从课程学习的基本原理出发，建立了“难度测量器+训练调度器”的课程框架；随后分别从速度性能和地形适应能力两个维度设计了自适应课程策略。速度课程采用纵向线速度与横摆角速度的联合概率分布决定运动控制指令的更新方向，使策略在高速与高转向耦合条件下仍能保持运动敏捷性，最大稳定线速度达到 6.2 m/s（弗劳德数 9.8），最大横摆角速度达到 9 rad/s。地形课程利用教师-学生结构中的特权观测空间实现本体感受条件下的地形感知，并通过足端临近点高度估计增强落足安全性，训练后机器人可爬上 12 cm 台阶、攀登 45 °坡道、跨越 18 cm 障碍。针对速度与地形课程同时训练时相互制约的问题，本章提出了基于地形类型的速度采样截断策略，使双课程在融合后协同工作，地形难度收敛至 6 级（高于单一课程的 5 级），同时速度采样区域持续扩展。整体来看，本章证明了课程学习是提升四足机器人强化学习训练稳定性、采样效率和综合运动能力的有效方法。

50 武汉科技大学本科毕业论文 5 结果与分析本章按“总体性能对比→仿真迁移实验→实机部署验证→失败案例→综合讨论”的顺序展开。前部分（5.1-5.3）展示完整实验证据链：首先在仿真环境中系统验证自适应奖励调度的相对增益，再通过 PyBullet 迁移仿真和真实机器人实验验证方法的 sim-to-real 可迁移性；后部分（5.4-5.5）通过失败案例分析与综合讨论对方法机理和适用边界进行深入分析。

5.1 总体性能对比本文方法与四个基线方法在 5 个测试等级上的综合得分 S 对比如表 5-1 所示。本文方法在 L2-L5 等级上均显著优于基线，特别是在 L4（台阶）与 L5（混合扰动）等级上提升最大；在 L1（平坦）等级上与 HIMLoco 基线持平，验证“基础能力守恒”假设。

表 5-1 给出全部测试场景上的指标平均。本文方法在通过率上较 HIMLoco 提升 7.2 个百分点 (0.738→0.810)，速度跟踪误差降低 14.5% (0.318→0.272)，跌倒率降低 38.6% (0.057→0.035)，能耗仅上升 3.1% (1.18→1.22)。综合得分 S 从 0.498 提升至 0.557 (+11.8%)。

表 5-1 全部测试场景平均指标（均值±标准差，5 种子）方法 ps↑ev(m/s) ↓pf↓E↓S↑Vanilla PPO 0.612±0.031 0.412±0.018 0.094±0.012 1.21±0.07 0.371±0.022 DR 0.683±0.025 0.358±0.014 0.072±0.009 1.31±0.06 0.435±0.019 RMA 0.705±0.022 0.341±0.013 0.066±0.008 1.27±0.05 0.460±0.018 HIMLoco 0.738±0.020 0.318±0.011 0.057±0.007 1.18±0.05 0.498±0.016 Ours 0.810±0.018 0.272±0.010 0.035±0.005 1.22±0.05 0.557±0.015 所有“Ours vs. HIMLoco”比较的 Welch t-检验 p 值在 ps, ev, pf, S 四项上均<0.01，能耗

差异不显著 ($p=0.42$), 说明本文方法以可忽略的能耗代价换取显著的稳定性与跟踪性提升。

5.2 仿真迁移实验为验证本体感知强化学习策略在仿真环境中的运动能力与泛化性能, 本章首先在 PyBullet 物理仿真环境中对训练得到的控制策略进行系统迁移测试, 涵盖速度跟踪、极限机动、低附着路面、变负载以及多种越野地形等典型工况。

51 武汉科技大学本科毕业论文仿真环境与实验平台仿真迁移测试在 PyBullet 物理引擎中搭建, 如图 5-1 所示。机器人模型选用 Unitree A1 (12 自由度), 仿真步长 0.005 s, 控制频率 50 Hz。迁移测试时, 将 Isaac Gym 训练的策略网络权重直接加载至 PyBullet 环境中, 不再进行任何在线训练或参数调整。测试环境包含平坦、随机粗糙、上下台阶、连续斜坡、坑洼越野及混合地形六类地形, 每类地形设置多个随机种子重复试验以消除偶然性。

图 5-1 PyBullet 迁移仿真环境。左侧为平坦地形测试场景, 右侧为随机粗糙地形测试场景, 机器人需在本体感知条件下完成速度跟踪与姿态稳定。

速度性能迁移验证速度迁移实验考察策略在不同前向速度命令下的跟踪精度与稳定性。图 5-2 给出机器人在低、中、高三种速度指令下的运动截图。实验结果表明, 策略在 0.5~3.5 m/s 的宽速度范围内均能保持稳定的 trot 步态, 速度跟踪误差随命令速度增大略有上升但始终控制在 0.15 m/s 以内。

(a)低速指令 (0.5 m/s) (b)中速指令 (2.0 m/s) (c)高速指令 (3.5 m/s) 图 5-2 不同速度指令下的迁移仿真运动截图。策略在 0.5~3.5 m/s 范围内均可保持稳定运动, 足端触地节律清晰、躯干姿态平稳。

在速度性能对比方面, 分别测试了 1.0、2.0、3.0 m/s 三个等级下的最大稳定速度保 52 武汉科技大学本科毕业论文持情况。结果表明, 低速区段跟踪精度最高 (均方根误差 <0.03 m/s), 中速区段步态周期性最为稳定 (触地相位偏移标准差 <0.02), 高速区段虽跟踪误差增大至约 0.08 m/s 但未发生跌倒。

极限速度与横摆角速度测试为进一步探索策略的运动能力边界, 测试了策略在极限速度命令下的表现。图 5-3 给出了纵向最大速度试验结果, 图 5-4 给出了最大横摆角速度试验结果。在 3.5 m/s 的极限前向速度指令下, 策略仍能维持稳定运动, 但姿态波动方差增大至平坦地形的约 2.5 倍, 表明已接近本体感知策略的速度上限。在横摆角速度测试中, 策略可稳定跟踪最高 3.0 rad/s 的转向指令, 进一步增大指令则出现足端打滑和姿态失控。

(a)纵向速度跟踪时域曲线(b)速度-姿态关系分析图 5-3 最大纵向速度试验。策略在 3.5 m/s 极限速度指令下仍保持稳定, 姿态波动随速度增大呈超线性增长。

(a)横摆角速度跟踪时域曲线(b)转向半径与姿态关系图 5-4 最大横摆角速度试验。策略可稳定跟踪 3.0 rad/s 转向指令, 极限转弯半径下仍保持躯干水平度。

低附着路面验证将地面摩擦系数由默认的 0.8 降低至 0.15~0.30 区间以模拟冰面或湿滑地面, 考察策略在低附着条件下的适应性。图 5-5 给出了低附着路面下的运动时序与稳定性数据。

实验结果显示, 策略在摩擦系数 $\mu=0.2$ 时仍能保持前进, 但速度跟踪误差增大至平坦地面的约 2 倍 (从 0.05 m/s 增至 0.11 m/s), 足端滑移距离增大约 3 倍。值得注意的是, 策略在此工况下自动降低了步幅并增大了支撑相占比, 体现出对低附着环境的行为适应。

53 武汉科技大学本科毕业论文(a)低附着路面运动时序(b)速度与滑移率关系曲线图 5- 5 低附着系数路面工况试验 ($\mu=0.2$)。策略通过自适应调节步幅与支撑相占比保持运动稳定性, 速度跟踪误差较正常路面增大约 2 倍。

变负载鲁棒性验证在机器人躯干上分别附加 5 kg 和 10 kg 额外负载, 考察策略对质心偏移与惯量变化的鲁棒性。图 5-6 和图 5-7 分别给出了两种负载条件下的测试结果。在 5 kg 负载 (约占自重 40%) 下, 速度跟踪误差和能耗增加均不明显 ($<5\%$); 在 10 kg 负载 (约占自重 80%) 下, 速度跟踪误差增加约 15%, 关节力矩峰值上升约 30%, 但策略仍能保持稳定运动, 未见跌倒。这说明策略已通过域随机化学到了对质量扰动的不敏感性。

AI 68%

(a)5 kg 负载运动截图(b)5 kg 负载速度跟踪曲线图 5-6 5 kg 负载工况试验。附加 5 kg 负载后运动性能几乎无退化, 速度跟踪误差与能耗增加均 $<5\%$ 。

(a)10 kg 负载运动截图(b)10 kg 负载速度与力矩曲线图 5-7 10 kg 负载工况试验。附加 10 kg 负载后关节力矩峰值上升约 30%, 但仍能维持稳定运动, 未发生跌倒。

AI 70%

崎岖与坑洼越野地形在非结构化地形上测试策略的越野通过能力。图 5-8 给出崎岖越野地形下的连续运动截图, 图 5-9 为对应的速度与姿态数据。崎岖地形由随机高度 0~8 cm 的碎石状凸起组成, 策略通过自适应调整落足位置和躯干高度完成通过。图 5-10 和图 5-11 分别给出坑洼地形的截图与数据, 坑洼由随机深度 0~6 cm 的凹陷组成。从数据可见, 坑洼地形下躯干姿态波动(俯仰与翻滚方向)较平坦地形增大 2~3 倍, 但策略仍能在 80%以上的回合中完成全程通过。

AI 67%

54 武汉科技大学本科毕业论文(a)接近崎岖段(b)崎岖地形中段(c)通过崎岖段图 5-8 崎岖越野地形下的连续运动截图, 策略通过自适应落足调整应对高度变化 0~8 cm 的随机碎石凸起, 躯干保持基本水平。

AI 68%

(a)崎岖地形速度跟踪曲线(b)崎岖地形姿态波动曲线图 5-9 崎岖越野地形工况试验数据。速度跟踪误差在崎岖段显著上升但仍保持有界, 姿态波动方差较平坦地形增大 2~3 倍。

(a)坑洼地形入口(b)坑洼地形中段(c)脱离坑洼段图 5-10 坑洼越野地形下的连续运动截图。策略在随机深度 0~6 cm 凹陷中自动探索可行落足区域。

AI 66%

(a)坑洼地形速度与能耗曲线(b)坑洼地形触地状态变化图 5-11 坑洼越野地形工况试验数据。触地信号在坑洼区呈不规则切换模式, 能量消耗较平坦地形增加约 40%。

55 武汉科技大学本科毕业论文复合地形: 楼梯与坡道组合复合地形是最具挑战性的测试场景, 要求机器人在同一回合内依次通过楼梯段和坡道段, 对策略的步态切换能力和姿态恢复能力提出极高要求。图 5-12 给出上楼梯-下坡复合地形的关键帧序列, 图 5-13 为对应数据; 图 5-14 给出上坡-下楼梯地形的关键帧, 图 5-15 为对应数据。

AI 59%

在上楼梯-下坡场景中, 台阶高度 0.10~0.18 m, 下坡坡度约 20° 。策略在上楼梯段自动增大抬腿高度并降低前进速度, 转入下坡段后主动降低躯干俯仰角以防止前倾。上坡-下楼梯场景中, 上坡坡度约 18° , 下楼梯台阶高度 0.10~0.15 m。策略在上坡段通过增加前倾角维持推进力, 下楼梯段则通过缩短步幅和降低下落速度保证稳定落地。

AI 66%

(a)上楼梯段运动帧(b)下坡段运动帧图 5-12 上楼梯-下坡复合地形关键运动帧。台阶高度 0.10~0.18 m, 下坡坡度约 20° 。

策略在台阶段与坡道段之间自动完成步态参数切换。

(a)上楼梯-下坡速度与高度曲线(b)上楼梯-下坡姿态与力矩曲线图 5-13 上楼梯-下坡复合地形试验数据。台阶段抬腿高度显著增大, 坡道段躯干俯仰角主动调整以防止倾覆。

图 5-14 上坡-下楼梯复合地形关键运动帧。上坡坡度约 18° , 下楼梯台阶高度 0.10~0.15 m。

AI 66%

56 武汉科技大学本科毕业论文(a)上坡-下楼梯速度曲线(b)上坡-下楼梯姿态曲线图 5-15 上坡-下楼梯复合地形试验数据。下楼梯段关节力矩波动明显增大, 策略通过缩短步幅和降低下落速度保证稳定。

AI 70%

5.3 实机部署验证为进一步验证策略在真实物理环境中的可迁移性, 将仿真训练所得策略部署至 Unitree Go1 实物机器人上进行系列测试。本节依次展示硬件平台组成、高速运动、低附着路面、负载、复合地形与室外自然地形等工况下的实机运行结果。

AI 70%

硬件平台与实验系统实机验证平台如图 5-16 所示。硬件系统由 Unitree Go1 四足机器人(12 自由度)、板载 NVIDIA Jetson 计算单元、IMU、关节编码器及电机驱动器组成。策略推理在 Jetson 上以 50 Hz 频率运行, 输出十二维关节目标角偏移叠加至默认姿态, 经底层 PD 控制器以 200 Hz 频率跟踪。所有观测信号(关节角、角速度、IMU 角速度与重力方向)来自机器人本体传感器, 不依赖外部运动捕捉、视觉或激光雷达。

AI 70%

(a)本体感受控制实验设备总览(b)Go1 机器人硬件系统连接图图 5-16 本体感受四足机器人实验平台。硬件

系统包含 Unitree Go1 机器人、NVIDIA Jetson 计算单元与机载 IMU/编码器传感链路，策略仅依赖本体感受信息运行。

高速运动性能在平坦硬质地面上测试策略的高速奔跑能力，命令速度从 1.0 m/s 逐步提升至 3.5 m/s。

图 5-17 给出了 3.5 m/s 高速运动 1 s 内的关键帧。从帧序列可见，策略在该速度下仍能维持清晰的 trot 对角步态，足端触地与离地时刻分明。图 5-18 给出最大速度下的运动稳定性数据，前向速度实测值在 3.3~3.5 m/s 范围内波动，姿态偏差始终控制在安全范围以内。图 5-19 给出最高横摆角速度下的极限相位切换关键帧。

57 武汉科技大学本科毕业论文图 5-17 3.5 m/s 高速奔跑 1 s 内的连续关键帧。策略保持清晰的 trot 对角步态，足端触地与离地时刻分明，躯干姿态平稳。

图 5-18 最大速度下的运动稳定性数据。前向速度实测值在 3.3~3.5 m/s 范围内波动，姿态偏差始终控制在安全阈值以内。

58 武汉科技大学本科毕业论文图 5-19 最高横摆角速度下的极限相位切换关键帧。策略在 3.0 rad/s 转向指令下仍保持交替对角支撑，相位切换干净利落。

图 5-20 给出最大加速度下的运动稳定性数据。在加速度均值 1.5 m/s² 条件下，速度跟踪曲线平稳上升，无明显超调或迟滞。

图 5-20 最大加速度下的运动稳定性。速度跟踪曲线平稳上升，加速度均值约 1.5 m/s²，无明显超调或迟滞。

低附着路面验证在光滑瓷砖地面（摩擦系数估计约 0.25~0.35）上测试策略的低附着力适应性。

图 5-21 给出了低附路面上的运动场景照片，图 5-22 给出对应的稳定性数据。与仿真结果一致，策略在此工况下自动降低了步幅、增加了支撑相占比，速度跟踪稳定性略有下降 59 武汉科技大学本科毕业论文降但未发生失控打滑。

图 5-21 低附着路面（光滑瓷砖， $\mu \approx 0.25 \sim 0.35$ ）实机运动场景。策略通过增大支撑相占比与降低步幅自适应地调整运动模式。

图 5-22 低附着路面下的运动稳定性。速度跟踪稳定性略有下降但未发生失控打滑，姿态维持良好。

负载鲁棒性验证在机器人背部固定 3.5 kg 负载（约占自重 28%）进行负载适应性测试。图 5-23 给出负载条件下的运动帧图，图 5-24 为对应的速度与力矩稳定性曲线。结果显示，附加 3.5 kg 负载后，机器人仍能保持稳定运动，关节力矩峰值增加约 15%，速度跟踪误差与空载相比无明显退化（<3%）。

60 武汉科技大学本科毕业论文图 5-23 3.5 kg 负载下的敏捷运动帧图。负载条件下策略仍保持稳定步态，无明显姿态倾斜或速度退化。

图 5-24 3.5 kg 负载下的运动稳定性。速度跟踪误差与空载相比无明显退化（<3%），关节力矩峰值增加约 15%。

复合地形通过分别在“上楼梯-下坡”和“上坡-下楼梯”两种复合地形上进行实机测试，验证策略在连续地形变化中的适应能力。图 5-25 给出了两种复合地形的实机运行照片。图 5-26 给出了复合地形的稳定性测试数据，上楼梯段的通过成功率为 87%，下楼梯段为 82%，全程综合通过率为 78%。失败主要发生在台阶边缘足端滑脱，提示真实接触模型与仿真仍存在系统性差异。

61 武汉科技大学本科毕业论文(a)上楼梯-下坡地形快速通过(b)上坡-下楼梯地形快速通过图 5-25 复合地形实机验证。（左）上楼梯（0.10~0.15 m）-下坡（约 18°）；（右）上坡（约 18°）-下楼梯（0.10~0.15 m）。

图 5-26 复合地形实机运行稳定性数据。上楼梯段通过率 87%，下楼梯段通过率 82%，全程综合通过率 78%。

室外自然地形测试为评估策略在非受控自然环境中的适应能力，在四种典型室外地形上进行了实机行走测试。图 5-27 依次给出灌木丛脱离、草地平地小跑、草地爬坡和铺装石板路行走四个场景的运动截图。

(a) 灌木丛脱离（图 5-27a）：机器人在高度约 30~50 cm 的低矮灌木丛中运动，枝叶持续施加不规则外力扰动，策略通过本体的姿态感知信号在线调整步态，完成穿越。

该场景重点检验了策略对外力的抗扰恢复能力。

AI 70%

(b) 草地平地小跑 (图 5-27b): 在软质不平整草地上以 1.5 m/s 速度小跑, 草地表面柔软且伴随微小起伏, 足端接触与硬质地面存在明显差异。策略在软地面仍能维持 trot 节律, 但触地持续时间略有延长。

AI 69%

(c) 草地爬坡 (图 5-27c): 在坡度约 15° 的草坡上运动, 兼具软地面与坡度双重挑战。策略在坡上保持前倾姿态以提供推进力, 并在坡顶过渡段平稳转入平坦运动。

62 武汉科技大学本科毕业论文 (d) 铺装石板路行走 (图 5-27d): 在具有不规则接缝和轻微台阶 (1~3 cm) 的石板铺设路面上行走, 检验策略在日常半结构化地面上的可靠性。在超过 100 m 的连续行走中无跌倒发生。

AI 69%

(a) 灌木丛脱离(b)草地平地小跑(c)草地爬坡(d)铺装石板路行走图 5-27 室外自然地形实机测试。四种典型室外场景分别验证策略在外力扰动、柔软地面、坡度组合与半结构化路面上的适应能力。

AI 69%

多工况综合成功率图 5-28 汇总了所有测试工况下的通过成功率对比。结果表明, 本体感知强化学习策略在绝大多数工况下均达到 80% 以上的通过成功率。其中平坦地形 (高速、低附、负载) 通过率均超过 90%; 越野地形 (崎岖、坑洼) 通过率在 80%~88% 之间; 复合地形 (楼梯+坡道组合) 通过率约 78%~82%; 室外场景中草地与石板路通过率接近 100%, 灌木丛脱离因外力扰动较大, 通过率约 85%。综合平均成功率约 89.5%。

AI 70%

图 5-28 多工况下的通过成功率汇总。本体感知策略在绝大多数工况下均达到 80% 以上通过率, 综合平均成功率约 89.5%。

5.4 失败案例与可解释性对未通过回合进行抽样分析后可以发现, 失败主要集中在三种模式。其一是台阶踩空, 即足底接触特征瞬间下降, 但难度估计未能及时响应, 导致稳定项权重抬升滞后, 这类情况约占失败回合的 42%; 其二是斜坡侧滑, 即下坡侧风险特征 f_g 与 f_v 同时升高, 引起调度器输出震荡, 这类情况约占 31%; 其三是推力扰动后的过冲, 即扰动消失后调度器仍维持较高稳定权重, 导致策略过度保守并使跟踪误差增大, 这类情况约占 19%。

AI 69%

其余 8% 的失败则主要来自仿真数值不稳定造成的非典型情形。

失败模式 1 提示需要引入“前瞻”机制——例如基于历史接触序列的短时序预测; 失败模式 2 提示在权重输出端加入正则化项以抑制震荡; 失败模式 3 提示难度分数下降阶段的恢复速度可独立调节。这些改进方向构成本文工作的自然延伸, 将在第 6 节展开讨论。

AI 70%

5.5 综合讨论综合上述结果可知, 本文方法在跨地形场景下的稳定性、跟踪精度与综合得分上均优于固定权重基线, 且能耗增加可忽略。结合仿真迁移与实机测试结果可见, 本体感知强化学习策略具备良好的 sim-to-real 可迁移性: 在仅依赖 IMU 与关节编码器的条件下, 成功实现了从仿真训练到真实部署的直接迁移。优势来源主要有四: (i) 多源难度估计能精细识别风险, (ii) softmax 映射使权重切换平滑且有界, (iii) 双课程训练保证学习信号在速度与地形两个维度上均充分覆盖, (iv) 域随机化使策略对质量、摩擦、延时等物理参数分散具有鲁棒性。

AI 70%

方法局限同样明显: (i) 难度估计基于本体观测, 对外界环境变化的预判能力有限, 在台阶踩空等需前瞻的场景中响应滞后; (ii) 调度参数 α, β 仍需人工先验, 不同机器人平台可能需重新标定; (iii) 极端突变场景下平滑机制可能造成响应滞后。此外, 实机测试暴露出的台阶边缘足端滑脱问题提示仿直接触模型与真实物理仍存在系统性差距。这些局限提示未来可结合外部感知 (视觉、激光雷达) 与元学习进一步增强调度器自适应性。

AI 60%

工程上, 本文方法不增加传感器、不修改主网络、不显著增加计算开销, 可作为现有 HIMLoco 风格控制器的“即插即用”模块。实机验证进一步表明, 本体感知策略可在低端板载计算单元上以 50 Hz 实时运行, 配合底层 200 Hz PD 控制器, 满足实际部署的实时性要求。~80 行代码的额外实现成本与~11.8% 的综合得分提升构成了良好的工程性价比。

AI 70%

5.6 本章小结本章从总体对比、仿真迁移实验、实机部署验证、失败案例与综合讨论五个角度对所提自适应奖励调度方法进行系统评测。仿真实验表明本文方法在不牺牲基础能力的前提下显著提升跨地形稳定性, 迁移实验与实机测试进一步验证了策略的 sim-to-real 可迁移性和工程可行性, 共同佐证了第三章方法设计的有效

性与实用性。

64 武汉科技大学本科毕业论文 6 结论与展望 6.1 研究工作总结本文要解决的问题是四足机器人想在复杂地形上同时跑得快、站得稳、省能量、扛得住扰动，但固定奖励权重没法适配地形风险变化。理论部分从四足机器人机构运动学、trot 步态接触规律、马尔可夫决策过程、PPO 优化目标和 Actor-Critic 网络结构切入，分析了为什么无模型强化学习控制器能直接学关节目标动作，但训练效果又严重受奖励权重设置影响。方法层面以 HIMLoco 风格的本体感知控制框架为基础，把地形风险估计从策略主干里分离出来，搭了一条“本体特征提取—难度分数估计—奖励权重映射—平滑与变化率约束—异常回退”的自适应奖励调度管线。这套管线不需要外部视觉或激光雷达，不改变部署时的策略输入，也不加新的神经网络，工程接入成本比较低。

围绕上述方法，本文还设计了速度-地形双课程训练机制。速度课程逐步扩大命令速度范围，让策略先掌握地面上的基本运动控制能力；地形课程从平地、坡地、粗糙地形到台阶和离散障碍逐级增加接触复杂度，确保策略在训练分布中能连续接触到不同风险等级。奖励调度器在每个训练样本上根据姿态扰动、速度偏差、接触一致性、力矩波动和动作变化这些本体信号调整速度项、能耗项、稳定项和恢复项的权重，让训练目标随着状态风险连续变化。和直接加大网络规模或者加外感知不同，本文的核心思路是调整“评价标准”而不是改“策略结构”，所以它可以作为轻量模块嵌到已有的四足机器人强化学习训练流程里去。

实验部分在并行物理仿真环境里搭了覆盖五类地形、五个随机种子和多组对照基线的评测协议。结果显示，本文方法在综合得分、通过率、跌倒率和恢复成功率这些指标上都优于固定权重的 HIMLoco 基线，特别是在台阶、离散障碍和混合扰动这些高风险场景里优势更明显。进一步的消融实验说明，难度估计、权重平滑、变化率裁剪和速度-地形双课程对最终性能都有贡献。整体来看，本文走完了从理论分析、方法设计到仿真和实机实验验证的完整闭环。

6.2 主要结论综合全文推导与实验结果，可以得到以下结论。

固定奖励权重是跨地形强化学习控制中一个绕不开的瓶颈。地面上的高速跟踪目标和复杂地形里的稳定恢复目标在一些场景下就是互相冲突的，一组权重很难同时覆盖所有风险等级。比如说机器人上了台阶或者进了离散障碍区，要是速度奖励还占大头，策略就容易带着过大的前向冲量往前冲，结果足端落点不稳、躯干俯仰角变大甚至摔倒。

本文的做法是在线调度奖励权重，让高风险状态下稳定项和恢复项权重上去、速度项权重适当降下来，这个冲突就缓解了不少。

本体感知信号虽然看不到地形长什么样，但也能做出有效的地形难度估计。本体观测确实不像高度图或视觉那样能提前预览地形几何，可姿态角速度、足端接触切换、关节力矩突变和动作变化率这些信号已经能反映出机器人和地形交互之后的风险状态了。

65 武汉科技大学本科毕业论文 实验中难度分数在接触切换、台阶跨越和外部扰动阶段都出现了明显上升，和机器人实际运动状态是对得上的。这说明在低成本或者感知受限的条件下，本体信号照样能作为奖励调度的可靠依据。

奖励调度不能瞎变，得受连续性约束。时变奖励确实能让训练目标更灵活，但权重变化太快会放大优势估计的噪声，把 PPO 截断目标依赖的近端更新假设给破坏掉。本文用了指数平滑和变化率裁剪之后，权重向量在相邻控制步之间变化有界，调度器既能响应风险变化，又不会引入不可控的扰动。这说明平滑机制不止是一个工程细节，而是保证自适应奖励能真正训出来的关键条件。

速度-地形双课程能提高策略训练的覆盖范围和泛化能力。要是上来就把高速命令和复杂地形同时扔给策略，早期肯定频繁摔倒、奖励稀疏、价值估计也不稳定；可要是只在平地上练，策略到了复杂接触场景又缺乏经验。双课程按先易后难安排任务分布，让策略逐步掌握基础速度跟踪能力和复杂地形接触经验，给奖励调度提供一个更稳定的训练基础。

表 6-1 本文工作的主要结论归纳结论类别具体含义奖励建模固定权重难以同时适配平地高速运动与复杂地

形稳定恢复需求，状态相关奖励权重更符合跨地形控制特性。

本体感知姿态扰动、接触一致性、力矩波动和动作变化能够反映地形风险，可在无外感知条件下驱动奖励调度。

AI 69%

优化稳定性平滑和变化率裁剪能够限制时变奖励对优势估计的扰动，是 PPO 稳定训练的重要保障。

训练策略速度-地形双课程降低了早期探索难度，并提升了高风险地形下的通过率与恢复能力。

工程价值调度器不改变策略主干和部署观测，计算开销小，适合嵌入现有四足机器人强化学习训练流程。

AI 84%

6.3 方法局限与适用边界尽管本文方法在仿真评测中取得了较为稳定的改进，但仍存在明确的适用边界。首先，难度估计完全建立在本体观测上，因此更适合“接触后风险识别”而不是“接触前地形预判”。当机器人高速接近突然出现的空洞、尖锐障碍或高落差台阶时，仅依赖本体信号可能存在响应滞后。未来若要处理高速越障或更强的自主导航任务，需要结合视觉、深度相机或激光雷达等外感知信号，使调度器具备一定前瞻能力。

AI 69%

其次，本文调度器仍包含人工设定的权重映射参数。虽然这些参数具有明确物理含义，调试成本低于重新训练大型策略网络，但不同机器人平台、不同足端结构和不同任务速度范围仍可能需要重新标定。本文通过实验验证了参数设计的有效性，但尚未系统研究参数对机器人质量、腿长、执行器带宽和地形尺度变化的敏感性。因此，本文方法 66 武汉科技大学本科毕业论文更适用于同类四足平台之间的迁移，跨形态机器人推广仍需重新设计难度特征和权重先验。

AI 69%

再次，本文实验主要在仿真环境中完成。虽然训练阶段引入了摩擦、质量、观测噪声、控制延迟和外力扰动等随机化因素，但真实硬件中的电机温升、减速器间隙、足端材料磨损、通讯丢包和传感器长期漂移等现象难以完全由仿真覆盖。仿真结果能够说明方法机制的合理性和相对性能优势，但不能替代真实机器人长期运行测试。后续工作需要在实物平台上完成分阶段部署验证，特别是长时间巡航、连续台阶、湿滑地面和室外不规则地形等场景。

AI 70%

最后，本文关注的是底层运动控制中的奖励权重调度，并未解决全局导航、语义任务规划、人机共融安全等上层问题。若将该方法用于巡检、救援或物流系统，还需要与路径规划、避障感知、任务调度和安全监控模块协同设计。换言之，本文方法应被理解为四足机器人运动控制管线中的一个稳定性增强模块，而不是完整自主机器人系统的全部解决方案。

AI 70%

6.4 工程部署与 Sim2Real 展望从工程部署角度看，本文方法具有较低的推理开销。策略网络仍输出 12 维关节目标增量，调度器只在训练或日志分析阶段根据本体特征计算奖励权重；若需要在线监控，也只需进行若干滑动窗口统计、线性融合、softmax 映射和平滑裁剪运算。该计算量远小于策略网络前向传播和物理控制循环，适合部署在 Jetson Orin、NUC 或四足机器人自带主控计算单元上。

AI 70%

真实硬件部署可采用逐级验证路线。第一阶段在仿真中完成理想环境训练，确保策略在平地、坡地、粗糙地形和台阶场景中具备基础性能；第二阶段引入强域随机化和控制延迟，构造近真实环境，观察奖励权重是否在噪声条件下保持平稳；第三阶段进行悬空台架测试，检查策略输出、关节限位和紧急停止逻辑；第四阶段在室内平地低速测试，再逐步扩展到中高速、坡地、人工台阶和室外混合地形。每一阶段都应设置独立通过标准，例如最大姿态角、关节力矩峰值、电机温度、跌倒次数和人工接管次数等。

AI 69%

Sim2Real 迁移中最需要关注的是接触模型失配与传感链路延迟。足底接触冲击在仿真中通常由刚体接触近似表示，而真实足端会受到橡胶材料、地面弹性和微小滑移的影响；编码器、IMU 与电机控制器之间也存在非同步采样和通讯延迟。为降低这些因素的影响，后续部署应在训练阶段加入更宽范围的摩擦随机化、质量扰动、动作延迟、观测噪声和推力扰动，同时在控制端设置动作低通滤波与安全限幅。对于奖励调度器而言，还需保证难度分数不会因传感噪声产生高频抖动，因此滑动窗口长度和平滑系数在硬件上应采用比仿真更保守的设置。

AI 69%

在应用层面，本文方法更适合对运动稳定性要求高、外感知条件受限或成本敏感的四足机器人任务，如厂区巡检、仓储坡道通行、应急环境初步探索和科研平台跨地形实验。对于需要高速越障、视觉导航或复杂语义

交互的任务，本文方法仍需与外感知和上层规划结合。部署过程中还应建立安全边界：当躯干姿态角、关节温度、足端打滑时间或调度器难度分数长期超过阈值时，系统应主动降速、切换安全步态或进入保护姿态，67 武汉科技大学本科毕业论文避免策略在分布外状态中继续执行高风险动作。

AI 72%

6.5 后续研究方向后续工作可从四个方面继续推进。第一，研究多模态难度估计。视觉或深度传感器能够提前获取地形高度变化，本体感知能够反映实际接触后的动力学风险，二者结合有望形成“接触前预判—接触后修正”的双层风险估计机制。该方向的关键不是简单增加传感器，而是如何在光照变化、运动模糊和传感延迟下保持风险表征稳定。

AI 76%

第二，研究可学习的奖励调度参数。本文采用人工先验设计 α 与 β ，保证可解释性和低成本。未来可以在保持物理约束的基础上，引入小规模元学习或贝叶斯优化，使权重映射参数能够随机器人平台和任务分布自动调整。需要注意的是，自动化调参不应牺牲调度器的稳定性和可解释性，否则会重新陷入黑箱奖励工程的问题。

AI 69%

第三，开展真实硬件长时运行验证。相比短时演示，长时运行更能暴露足端磨损、电机温升、IMU 漂移、通讯中断和地形分布变化等工程问题。后续应在真实四足平台上设计由平地、坡地、台阶、碎石和混合障碍组成的连续测试路线，记录多小时运行中的跌倒率、人工接管次数、能耗、部件温度和策略输出稳定性，从而评估本文方法的实际部署价值。

AI 64%

第四，将奖励调度思想推广到更一般的机器人学习问题。对于双足机器人、人形机器人、机械臂柔顺装配和无人机抗扰飞行等任务，多目标奖励冲突同样普遍存在。若能够根据状态风险在线调节“效率—稳定—安全—能耗”之间的偏好，奖励调度可能成为连接强化学习与经典增益调度控制的一种通用方法。未来可从 Lyapunov 稳定性、约束强化学习和多目标优化角度进一步完善其理论基础。

AI 70%

综上，本文工作证明了本体感知驱动的自适应奖励调度在四足机器人跨地形强化学习控制中的有效性。该方法并不试图用复杂网络取代已有控制框架，而是从奖励评价机制入手，在保持策略结构简洁的同时提升复杂地形下的稳定性和鲁棒性。随着真实硬件验证、多模态感知融合和自动化参数优化的进一步推进，本文方法有望为低成本、高鲁棒的腿足机器人运动控制提供一种可复用的技术路径。

68 武汉科技大学本科毕业论文参考文献[1]HWANGBO J, LEE J, HUTTER M. Per-contact iteration method for solving contact dynamics in legged robots[J]. IEEE Robotics and Automation Letters, 2019, 4(2): 20482055.

[2]KUMAR A, FU Z, PATHAK D, et al. Rma: Rapid motor adaptation for legged robots[C]//Robotics: Science and Systems (RSS). 2021.

[3]RUDIN N, HOELLER D, REIST P, et al. Learning to walk in minutes using massively parallel deep reinforcement learning[C]//Conference on Robot Learning (CoRL). 2022.

[4]MIKI T, LEE J, HWANGBO J, et al. Learning robust perceptive locomotion for quadrupedal robots in the wild[J]. Science Robotics, 2022, 7(62): eabk2822.

[5]LEE J, HWANGBO J, WELLHAUSEN L, et al. Learning quadrupedal locomotion over challenging terrain[J]. Science Robotics, 2020, 5(47): eabc5986.

[6]AGRAWAL A, KUMAR A, MALIK J, et al. Vision-aided quadrupedal locomotion in the wild[A]. 2022.

[7]MARGOLIS G, YANG G, AGRAWAL P. Walk these ways: Tuning robot control for generalization with reinforcement learning[C]//Conference on Robot Learning (CoRL). 2023.

[8]LONG J, WANG Z, LI Q, et al. Hybrid internal model: Learning agile legged locomotion with simulated robot response[Z]. 2024.

[9]PENG X B, COUMANS E, ZHANG T, et al. Learning agile robotic locomotion skills by imitating animals[C]//Robotics: Science and Systems (RSS). 2020.

[10]FU Z, KUMAR A, NACHUM O, et al. Minimizing energy consumption leads to the emergence of gaits in

legged robots[C]//Conference on Robot Learning (CoRL). 2021.

[11]MAKOVIYCHUK V, WAWRZYNIAK L, GUO Y, et al. Isaac gym: High performance gpu-based physics simulation for robot learning[J]. NeurIPS Datasets and Benchmarks,2021.

AI 68%

69 武汉科技大学本科毕业论文致谢本论文的完成离不开 ROBOCON 比赛, 是这个平台让我们接触了四足领域。从状态机位置控制到 VMC,从传统控制到强化学习, ROBOCON 的赛道设计和比赛氛围激励我们不断探索和创新。在机器人控制领域完成了深入的研究。

AI 50%

感谢实验室队友在硬件设计, 机械设计装配的帮助, 没有团队的帮助个体的力量终究有限; 感谢 HIMLoco 项目的开源贡献, 开源项目为该领域的发展有不可磨灭的贡献, 为本研究提供了高质量的基线实现与对比参考。

在此, 我还要特别感谢我的女友和挚友。树人树德, 大学不仅是学术成长的阶段, 更有诗和远方。

最后, 感谢评阅老师与答辩委员会对本论文的认真审读与宝贵意见, 所有改进将在后续工作中逐一落实。